

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего
образования
«Московский государственный технический университет имени Н. Э. Баумана»

Итоговый отчет по дипломной работе

**Анализ нейросетевых подходов решения задачи
прогнозирования респираторной болезни на
основе анализа звукозаписи дыхания**

Выполнил: студент

Руководитель: _____

Москва, 2026

Оглавление

Введение	3
1 Постановка задачи и обзор подходов	5
1.1 Задача классификации дыхательных аудиофрагментов	5
1.2 Набор данных и целевые классы	6
1.3 Математическая постановка задачи	7
1.4 Рассматриваемые семейства моделей	10
1.5 Классические признаки и линейная классификация	11
1.6 Сверточные архитектуры на спектрограммах	13
1.7 Сверточно-рекуррентные архитектуры	14
1.8 Трансформерный подход к спектрограммам	16
1.9 Метрики качества	17
1.10 Экспериментальная постановка	19
2 Теоретическое описание выбранного решения	21
2.1 Общий конвейер AST-Base	21
2.2 Выбор и описание набора данных	21
2.3 Входной аудиофрагмент и спектральное представление	24
2.4 Акустические признаки целевых классов	28
2.5 Патчи спектрограммы и вход трансформера	29
2.6 Перенос обучения и классификационная голова	33
2.7 Функция потерь и учет дисбаланса	35
2.8 Организация обучения, валидации и ограничения	37
2.9 Обоснование выбора AST-Base	40
3 Практическая реализация и анализ результатов	45
3.1 Среда и подготовка данных	45
3.2 Практическая работа с данными перед обучением	47
3.3 Исследованные AST-настройки	49
3.4 Метрики и протокол оценки	50
3.5 Метрики не-AST подходов	50
3.6 Результаты	53

3.7	Сравнение с не-трансформерными подходами	57
3.8	Выводы по практической части	58
Заключение		60
Список литературы		62
A	Конфигурации экспериментов	64
A.1	Подготовка индекса данных	64
A.2	Команды AST-экспериментов	64
A.3	Гиперпараметры	64
A.4	Модульная структура реализации	65

Введение

Дыхательные аудиозаписи являются удобным объектом для задач автоматической классификации аудиосигналов. Такой тип данных может быть получен без сложного измерительного оборудования, допускает повторные измерения и может использоваться для последующего анализа большого числа коротких фрагментов. При этом ручной анализ аудиозаписей плохо масштабируется, зависит от качества записи, условий получения сигнала и единообразия разметки.

В работе рассматривается задача классификации коротких фрагментов дыхательных аудиозаписей по датасетной разметке. В качестве целевых классов используются состояния дыхательного цикла: `normal`, `crackle`, `wheeze` и `both`. Результат работы модели интерпретируется как классификация аудиофрагмента, а не как самостоятельное медицинское заключение. Такое ограничение важно, поскольку используемые данные содержат акустические события и не задают полноценную клиническую постановку диагноза.

Сырой набор данных требует отдельного конвейера предварительной обработки. Записи отличаются длительностью, частотой дискретизации, уровнем шума и устройствами записи. Размеченные дыхательные циклы имеют разную продолжительность, а распределение классов является несбалансированным. Поэтому качество модели нельзя оценивать только по обычной доле правильных ответов: необходимо использовать метрики, учитывающие редкие классы и ошибки по каждому классу.

Методы машинного обучения позволяют автоматически выделять признаки, связанные с характерными акустическими событиями, такими как хрипы `crackle`, свистящие компоненты `wheeze` и их совместное появление. В работе сравниваются несколько семейств моделей: классические модели на ручных признаках, сверточные сети на логарифмических мел-спектрограммах, сверточно-рекуррентная модель и трансформерная архитектура `Audio Spectrogram Transformer`.

Цель работы состоит в исследовании качества современных методов анализа дыхательных аудиозаписей и выборе базовой архитектуры размером менее 100 млн параметров для последующего предметно-

ориентированного обучения.

Объектом исследования являются аудиозаписи дыхания. Предметом исследования являются методы классификации дыхательных аудиосигналов на основе ручных признаков, спектрограмм и предварительно обученных нейросетевых представлений.

Для достижения цели решаются следующие задачи:

1. разработать воспроизводимый конвейер подготовки аудиосегментов из сырого набора данных;
2. сформировать пациент-независимые обучающую, валидационную и тестовую выборки;
3. реализовать базовую модель на ручных признаках;
4. реализовать модели ResNet, CRNN и AST-Base для классификации логарифмических мел-спектрограмм;
5. сравнить не-трансформерные архитектуры и пять лучших AST-подходов по accuracy, balanced accuracy, macro F1, weighted F1 и полноте по каждому классу;
6. проанализировать ограничения полученного решения и направления дальнейшего развития.

Практическим результатом работы является программная реализация конвейера обработки данных, обучение нескольких моделей и оценка качества классификации на тестовой выборке. Итоговая архитектура AST-Base содержит 86м параметров, укладывается в заданное ограничение и после калибровки показывает наилучшие значения агрегированных метрик среди проведенных экспериментов.

Глава 1. Постановка задачи и обзор подходов

1.1 Задача классификации дыхательных аудиофрагментов

В работе рассматривается классификация коротких дыхательных аудиофрагментов по четырем классам: `normal`, `crackle`, `wheeze` и `both`. Класс `normal` соответствует фрагментам без размеченных дополнительных дыхательных событий. Класс `crackle` соответствует коротким прерывистым хрипам, класс `wheeze` – более протяженным свистящим компонентам, а класс `both` описывает совместное наличие двух типов событий.

Пусть x_i обозначает аудиосегмент, выделенный из исходной записи, а y_i – его целевую метку. Тогда задача записывается как построение функции классификации:

$$f_{\theta}(x_i) = \hat{y}_i, \quad \hat{y}_i \in \{0, 1, 2, 3\}, \quad (1.1)$$

где θ – параметры модели, а четыре числовых значения соответствуют классам `normal`, `crackle`, `wheeze` и `both`. Формула (1.1) задает классификацию аудиофрагмента, а не постановку медицинского диагноза.

Содержательно задача относится к автоматическому анализу дыхательных шумов. Врачебная аускультация опирается на выделение дополнительных дыхательных звуков, которые отличаются по длительности, частотному составу и положению внутри дыхательного цикла. В машинной постановке эти признаки должны быть извлечены из цифровой записи. Поэтому исходный временной сигнал необходимо преобразовать в представление, в котором короткие импульсные события и более длительные тональные компоненты остаются различимыми.

Класс `crackle` связан с короткими дискретными событиями. Они могут занимать малую часть дыхательного цикла и быть сопоставимыми по энергии с шумом записи. Класс `wheeze`, напротив, чаще проявляется как протяженный компонент с выраженной частотной структурой. Класс `both` является составным: для него требуется обнаружить признаки обоих типов в одном фрагменте. Поэтому задача не сводится к простому разделению «норма/патология». Модель должна различать несколько типов

акустических событий и учитывать их совместное присутствие.

Важной особенностью является неоднородность исходных записей. Дыхательные звуки зависят от пациента, положения датчика, устройства записи, уровня фонового шума и длительности конкретного цикла. Даже для одного класса спектральный рисунок может заметно отличаться. Поэтому классификатор должен обобщать не абсолютный уровень громкости или индивидуальный профиль пациента, а устойчивые частотно-временные признаки дыхательного события.

1.2 Набор данных и целевые классы

Эксперименты выполняются на наборе дыхательных аудиозаписей ICBNI. Этот набор содержит WAV-файлы и текстовые файлы разметки дыхательных циклов. Каждая строка разметки задает начало и конец цикла, а также два бинарных признака наличия `crackle` и `wheeze`. Целевой класс строится по правилу:

$$y = \begin{cases} \text{normal}, & c = 0, w = 0, \\ \text{crackle}, & c = 1, w = 0, \\ \text{wheeze}, & c = 0, w = 1, \\ \text{both}, & c = 1, w = 1, \end{cases} \quad (1.2)$$

где c обозначает наличие `crackle`, а w – наличие `wheeze`. Формула (1.2) используется при построении индексной таблицы сегментов.

Разбиение на обучающую, валидационную и тестовую выборки выполняется пациент-независимо. Это снижает риск того, что модель будет запоминать особенности конкретного пациента или устройства записи вместо акустических признаков класса.

Пациент-независимое разбиение принципиально отличается от случайного разбиения отдельных циклов. Если циклы одного пациента одновременно присутствуют в обучении и тестировании, модель может использовать устойчивые индивидуальные свойства записи: амплитудный масштаб, спектральный профиль микрофона, характерный шум помещения или повторяющийся тембр дыхания. В этом случае итоговая оценка будет завышенной, потому что проверка фактически выполняется на уже знакомом источнике данных. Разделение по пациентам делает оценку более

строгой и ближе к реальному применению на новых пациентах.

Набор данных также является несбалансированным. Сегменты без дополнительных событий встречаются чаще, чем сегменты с совместным наличием crackle и wheeze. Из-за этого модель, ориентированная только на минимизацию обычной ошибки классификации, может получить приемлемое значение ассигасы за счет уверенного распознавания класса normal, но при этом почти не распознавать редкий класс both. Поэтому дисбаланс классов должен учитываться и при выборе функции потерь, и при выборе метрик качества.

1.3 Математическая постановка задачи

Пусть задана обучающая выборка

$$D_{\text{train}} = \{(x_i, y_i)\}_{i=1}^N, \quad (1.3)$$

где x_i – аудиофрагмент дыхательного цикла, а $y_i \in \{1, 2, 3, 4\}$ – метка одного из четырех классов. Требуется построить параметрическую модель f_θ , которая по входному фрагменту оценивает распределение вероятностей по классам:

$$p_\theta(y = k \mid x_i) = \frac{\exp o_{ik}}{\sum_{j=1}^4 \exp o_{ij}}, \quad (1.4)$$

где o_{ik} – логит класса k для объекта x_i . Формула (1.4) задает вероятностный выход классификатора.

Правило принятия решения определяется максимумом апостериорной вероятности:

$$\hat{y}_i = \arg \max_{k \in \{1, 2, 3, 4\}} p_\theta(y = k \mid x_i). \quad (1.5)$$

Формула (1.5) используется для получения дискретной метки, по которой затем рассчитываются элементы матрицы ошибок.

Обучение модели можно записать как задачу минимизации эмпирического риска:

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{i=1}^N L(f_\theta(x_i), y_i) + \lambda \Omega(\theta), \quad (1.6)$$

где L – функция потерь, $\Omega(\theta)$ – регуляризатор, а λ – коэффициент регуляризации. Формула (1.6) является общей постановкой для всех рассматриваемых моделей: классического классификатора на ручных признаках, сверточной сети, сверточно-рекуррентной сети и трансформерной архитектуры.

Для несбалансированной выборки часто используется взвешенная перекрестная энтропия:

$$L_{\text{WCE}} = - \sum_{k=1}^4 w_k \mathbf{1}(y_i = k) \log p_{\theta}(y = k \mid x_i), \quad (1.7)$$

где w_k – вес класса k , а $\mathbf{1}$ – индикатор истинной метки. Формула (1.7) увеличивает вклад ошибок на малочисленных классах.

Для фокусировки на трудных примерах может применяться focal loss:

$$L_{\text{focal}} = -(1 - p_t)^{\gamma} \log p_t, \quad (1.8)$$

где $p_t = p_{\theta}(y = y_i \mid x_i)$, а γ управляет усилением вклада ошибочно классифицированных или неуверенно классифицированных объектов. Формула (1.8) особенно полезна в задачах, где простые объекты крупного класса могут доминировать в градиенте.

С точки зрения входных данных все модели можно представить как композицию преобразования признаков и классификатора:

$$f_{\theta}(x) = g_{\phi}(\psi(x)), \quad (1.9)$$

где ψ переводит аудиосигнал в признаковое представление, а g_{ϕ} выполняет классификацию. Для MFCC-подхода ψ задается вручную, для ResNet18 и CRNN – в значительной степени обучается сверточными слоями, для AST – включает патчевое представление спектрограммы и механизм самовнимания. Формула (1.9) показывает общность постановки и различие архитектурных решений.

Для анализа важно различать вероятностный выход модели и итоговую метку. Вероятности $p_{\theta}(y = k \mid x)$ отражают относительную уверенность модели, но сама классификация выполняется после применения правила (1.5). На несбалансированных данных это различие существенно: две

модели могут иметь похожие признаки и похожие логиты, но давать разные значения полноты редкого класса из-за разных порогов или смещений между классами. Поэтому в работе отдельно рассматривается калибровка логитов как изменение правила принятия решения без изменения признакового извлекавателя.

Обобщающая способность модели оценивается не на обучающей выборке, а на отложенной тестовой части. Формально требуется, чтобы модель минимизировала не только эмпирический риск (1.6), но и ожидаемый риск на новых пациентах:

$$R(\theta) = E_{(x,y) \sim P_{\text{test}}} L(f_{\theta}(x), y). \quad (1.10)$$

На практике распределение P_{test} неизвестно, поэтому оно приближается пациент-независимой тестовой выборкой. Формула (1.10) подчеркивает, что задача состоит не в запоминании записей, а в переносе решения на новые источники дыхательных сигналов.

Если обозначить множество пациентов как S , то корректное разбиение можно записать условием

$$S_{\text{train}} \cap S_{\text{val}} \cap S_{\text{test}} = \emptyset. \quad (1.11)$$

Формула (1.11) выражает требование, что один пациент не должен одновременно участвовать в обучении и проверке качества. В противном случае модель может использовать скрытые пациент-специфические признаки, не связанные с целевыми дыхательными событиями.

Целевая функция и метрика выбора модели не обязаны совпадать. Функция потерь используется для дифференцируемого обучения параметров, а macro F1 и balanced accuracy рассчитываются после дискретизации предсказаний. Поэтому обучение минимизирует гладкую surrogate-функцию, а выбор итоговой модели выполняется по метрике, которая ближе к предметной цели: равномерному качеству по всем классам.

1.4 Рассматриваемые семейства моделей

В качестве нижней границы качества используется классическая модель на ручных признаках. Из аудиосигнала извлекаются MFCC, спектральные статистики и энергетические признаки, после чего обучается логистическая регрессия. Такой подход быстро воспроизводится и показывает, насколько задача решается без глубокого обучения.

Вторая группа включает сверточную модель на логарифмических мел-спектрограммах. В работе используется ResNet18, адаптированная к одноканальному спектрограммному входу. Такая модель выделяет локальные частотно-временные паттерны, полезные для коротких хрипов и свистящих компонентов.

Третья группа представлена сверточно-рекуррентной моделью CRNN GRU. Сверточная часть извлекает локальные признаки спектрограммы, а GRU-слой моделирует временную структуру полученной последовательности. Этот вариант нужен как промежуточный ориентир между чисто сверточной обработкой и трансформерной архитектурой.

Основная группа экспериментов связана с Audio Spectrogram Transformer. AST-Base рассматривает логарифмическую мел-спектрограмму как последовательность патчей и обрабатывает ее блоками самовнимания [2]. Такой подход особенно важен для дыхательных сегментов, где признаки одного класса могут находиться в разных временных областях.

Перечисленные семейства образуют последовательное усложнение модели. Ручные признаки проверяют, достаточно ли простого спектрального описания. Сверточная сеть проверяет, насколько полезны локальные частотно-временные шаблоны. Сверточно-рекуррентная модель добавляет явное моделирование временного порядка. Трансформерная модель проверяет, дает ли выигрыш прямое связывание удаленных участков спектрограммы через механизм самовнимания. Такая логика сравнения позволяет оценивать не только итоговые числа метрик, но и вклад архитектурной идеи.

Общий вид сравниваемых направлений приведен на рисунке 1.1. Схема показывает, что различие между подходами возникает не только в классификационном слое, но и в способе получения признакового пространства. Ручные признаки заранее задают форму описания аудио.

Сверточные и сверточно-рекуррентные модели обучают часть признаков по данным. Трансформерный подход дополнительно меняет способ агрегации: вместо последовательного или локального накопления контекста используется сопоставление патчей спектрограммы.




Рис. 1.1: Семейства подходов к классификации дыхательных аудиофрагментов

1.5 Классические признаки и линейная классификация

Классический подход к анализу аудиосигнала строится на ручном выделении признаков. Наиболее распространенным представлением являются мел-частотные кепстральные коэффициенты MFCC [5]. Они описывают огибающую спектра в шкале, приближенной к восприятию частоты человеком. Для каждого короткого окна сигнала вычисляется спектр, затем энергия проецируется на мел-фильтры, логарифмируется и преобразуется дискретным косинусным преобразованием.

Преимущество MFCC состоит в компактности и интерпретируемости. Небольшое число коэффициентов описывает общий спектральный профиль, поэтому такой подход быстро обучается и не требует большого объема вычислений. Для дипломной работы MFCC + логистическая регрессия используется как нижняя граница качества: если глубокая модель не превосходит этот вариант, усложнение архитектуры не оправдано.

Ограничение ручных признаков связано с потерей детальной временной структуры. Если признаки усредняются по фрагменту, короткие события класса `crackle` могут быть сглажены. Если используются только агрегированные статистики, то модель не видит точного положения собы-

тий внутри дыхательного цикла. Для класса `wheeze` это также может быть недостаточно, потому что важна не только средняя энергия частотной области, но и длительность устойчивого тонального компонента.

Логистическая регрессия задает линейную границу в пространстве признаков. Это делает результат устойчивым и понятным, но ограничивает выразительность. Если классы разделяются сложными нелинейными частотно-временными паттернами, линейной модели недостаточно. Поэтому MFCC-подход полезен как контрольный эксперимент, но не ожидается как итоговое решение.

Для дыхательных записей ручные признаки также чувствительны к выбору способа агрегации. Если коэффициенты усредняются по всему сегменту, модель получает компактное описание, но теряет информацию о том, в какой момент произошел короткий хрип. Если сохранять статистики по нескольким временным областям, размер признакового пространства растет, а линейная модель остается ограниченной. Поэтому классический подход хорошо показывает нижнюю границу качества, но плохо масштабируется к составным событиям.

Еще одно ограничение связано с тем, что MFCC исторически разрабатывались для речевых сигналов. Дыхательные звуки имеют другую природу: они слабее структурированы, часто содержат шум контакта датчика и могут не иметь выраженной гармонической структуры. Поэтому MFCC полезны как универсальное спектральное описание, но не являются специализированным представлением для `crackle` и `wheeze`.

Архитектурно классический подход можно представить как цепочку фиксированных преобразований, показанную на рисунке 1.2. В этой схеме обучаемой является только последняя модель классификации, а все операции до нее задаются заранее. Это делает подход устойчивым и дешевым, но ограничивает его способность адаптироваться к специфике дыхательных шумов.




Рис. 1.2: Схема классификации на основе MFCC и линейной модели

1.6 Сверточные архитектуры на спектрограммах

Сверточные нейронные сети рассматривают log-mel спектрограмму как двумерное изображение, где одна ось соответствует времени, а другая — частоте. В таком представлении локальные фильтры могут выделять короткие всплески энергии, полосы частот и их сочетания. В работе проверялась ResNet18 [3], адаптированная к одноканальному спектрограммному входу.

Ключевой элемент ResNet — остаточная связь. Она позволяет обучать более глубокую сеть, передавая часть сигнала напрямую через блок. Если обычная последовательность сверточных слоев может деградировать при увеличении глубины, остаточные соединения упрощают оптимизацию и позволяют строить более устойчивые представления. Для дыхательных спектрограмм это важно, потому что низкие слои могут выделять простые локальные изменения энергии, а более высокие — их комбинации.

Сильная сторона ResNet18 состоит в умении выделять локальные частотно-временные признаки. Короткий `crackle` может быть представлен как небольшой локальный паттерн, а `wheeze` — как вытянутая структура вдоль временной оси. Свертки хорошо работают с такими локальными объектами и используют параметрическую экономию: один и тот же фильтр применяется во многих положениях спектрограммы.

Главное ограничение сверточной модели состоит в локальности. Глобальный контекст формируется постепенно, через увеличение рецептивного поля. Если признаки класса разнесены по разным участкам дыхательного цикла, модели требуется несколько слоев, чтобы связать эти участки. Кроме того, `pooling`-операции могут уменьшать временное разрешение, что нежелательно для коротких событий. Поэтому ResNet18 является сильным не-AST ориентиром, но не полностью решает проблему дальних зависимостей.

ResNet18 также чувствительна к масштабу спектрограммы и размеру входного окна. Если короткий crackle занимает малую область, после нескольких операций downsampling его вклад может стать слабым. Если же уменьшить степень downsampling, возрастает вычислительная стоимость и риск переобучения. Поэтому сверточная архитектура требует компромисса между локальной детализацией и устойчивым агрегированным представлением.

Положительной стороной ResNet является сравнительно небольшое число параметров относительно AST-Base. Такая модель проще обучается, быстрее выполняет inference и может быть полезна в ограниченных вычислительных условиях. Однако в данной задаче главным критерием является качество распознавания всех четырех классов, поэтому экономичность модели не компенсирует слабую полноту редкого класса.

Схема сверточного подхода приведена на рисунке 1.3. В отличие от MFCC-подхода, признаки здесь не задаются полностью вручную. Сверточные фильтры обучаются по данным и постепенно переходят от простых локальных изменений энергии к более сложным сочетаниям частотных полос и временных фрагментов.




Рис. 1.3: Схема сверточной обработки log-mel спектрограммы в ResNet-подходе

1.7 Сверточно-рекуррентные архитектуры

Сверточно-рекуррентная сеть CRNN объединяет два механизма: сверточный извлекатель признаков и рекуррентный слой для моделирования последовательности [4]. В проверенном варианте сверточная часть формирует последовательность признаков по времени, после чего GRU обрабатывает эту последовательность и накапливает информацию о

динамике дыхательного цикла.

Такой подход мотивирован тем, что дыхательный звук является временным процессом. В отличие от обычной CNN, CRNN явно задает порядок временных шагов и может учитывать зависимость текущего состояния от предыдущих участков. Это полезно для протяженных событий класса wheeze, где длительность и устойчивость частотной области важны для решения.

GRU проще, чем LSTM, и имеет меньше параметров. Он использует управляющие ворота для обновления скрытого состояния и может сохранять информацию на нескольких временных шагах. Для ограниченного объема данных это преимущество: модель получает механизм временной агрегации без чрезмерного роста числа параметров.

Ограничение CRNN состоит в последовательной обработке. Длинные зависимости передаются через скрытое состояние, поэтому удаленные участки спектрограммы взаимодействуют опосредованно. Если короткое событие появляется в начале фрагмента, а другой важный признак – ближе к концу, модели нужно сохранить релевантную информацию через всю последовательность. Кроме того, рекуррентные модели могут быть чувствительны к шуму и к способу сжатия частотной оси сверточным кодировщиком.

CRNN полезна как проверка гипотезы о важности временного порядка. Если бы главный источник ошибок заключался только в недостатке последовательного контекста, добавление GRU должно было бы заметно улучшить качество относительно чистой сверточной модели. Однако для дыхательных событий важна не только последовательность, но и сохранение слабых локальных признаков до стадии агрегации. Поэтому CRNN рассматривается как важный, но не окончательный этап сравнения перед трансформерным подходом.

Схема CRNN приведена на рисунке 1.4. Сверточная часть сначала сжимает спектрограмму в последовательность признаков, а рекуррентный слой затем проходит по этой последовательности во времени. Таким образом, модель явно учитывает порядок кадров, но качество итогового представления зависит от того, какие локальные события сохранились после сверточного кодировщика.




Рис. 1.4: Схема сверточно-рекуррентной классификации дыхательного сегмента

1.8 Трансформерный подход к спектрограммам

Трансформерный подход отличается тем, что строит связи между элементами входа через механизм самовнимания. В аудиоклассификации это означает, что спектрограмма сначала переводится в последовательность локальных представлений, а затем модель обучается определять, какие участки этой последовательности важны совместно. Для дыхательных сегментов это особенно существенно, потому что признаки *crackle* и *wheeze* могут находиться в разных временных областях.

По сравнению со сверточной сетью трансформер менее жестко привязан к локальному соседству. Свертка сначала обрабатывает ближайшие области и только затем через глубину сети расширяет контекст. Самовнимание позволяет уже в одном блоке сопоставить удаленные токены. Это не делает трансформер автоматически лучше, но дает ему архитектурное преимущество в задачах, где решение зависит от нескольких разнесенных признаков.

По сравнению с рекуррентной моделью трансформер не обязан переносить всю информацию через одно скрытое состояние. Каждый токен может обращаться к другим токенам напрямую, а классификационный токен агрегирует наиболее значимые признаки. Поэтому трансформерный подход рассматривается как основной кандидат для сравнения с MFCC, ResNet18 и CRNN GRU.

Недостаток трансформерных моделей состоит в высокой емкости и требовательности к данным. Без предварительного обучения такая модель может хуже обобщать на медицинской выборке ограниченного размера. Поэтому в работе выбран вариант с предварительно обученной AST-Base: он сочетает выразительность самовнимания и перенос общего аудиопредставления на задачу дыхательных звуков.

На рисунке 1.5 показан общий принцип трансформерной обработки спектрограммы. Сначала двумерное представление разбивается на патчи, каждый патч переводится в токен, затем добавляется позиционная информация. После этого блоки самовнимания строят связи между токенами, а классификационный токен используется для получения итоговой метки. В отличие от CRNN, взаимодействие удаленных участков не обязано проходить через последовательное скрытое состояние.




Рис. 1.5: Схема трансформерной обработки спектрограммы

1.9 Метрики качества

Для несбалансированной четырехклассовой задачи недостаточно использовать только ассигуру. Эта метрика может быть высокой даже тогда, когда редкий класс `both` распознается плохо. Поэтому основная оценка строится на `macro F1` и `balanced accuracy`.

Для класса k `precision`, `recall` и `F1` задаются формулами:

$$P_k = \frac{TP_k}{TP_k + FP_k}, \quad R_k = \frac{TP_k}{TP_k + FN_k}, \quad (1.12)$$

$$F1_k = \frac{2P_k R_k}{P_k + R_k}. \quad (1.13)$$

`Macro F1` вычисляется как среднее значение $F1_k$ по всем классам:

$$\text{MacroF1} = \frac{1}{4} \sum_{k=1}^4 F1_k. \quad (1.14)$$

`Balanced accuracy` вычисляется как средняя полнота классов:

$$\text{BalancedAccuracy} = \frac{1}{4} \sum_{k=1}^4 R_k. \quad (1.15)$$

Формулы (1.12)–(1.15) отражают основную логику оценки: каждый класс должен влиять на итоговую метрику независимо от того, сколько сегментов этого класса содержится в тестовой выборке.

Дополнительно может использоваться weighted F1:

$$\text{WeightedF1} = \sum_{k=1}^4 \frac{n_k}{N} F1_k, \quad (1.16)$$

где n_k – число объектов класса k , а N – общее число объектов. Формула (1.16) учитывает фактическую долю классов в выборке. Эта метрика полезна как характеристика среднего качества на естественном распределении данных, но она может скрывать слабость редкого класса `both`.

Обычная ассигасу задается выражением:

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}(\hat{y}_i = y_i). \quad (1.17)$$

Формула (1.17) проста, но в текущей задаче является вспомогательной. При сильном преобладании класса `normal` модель может получить высокую ассигасу, если хорошо распознает только этот класс. Поэтому итоговый выбор модели должен опираться прежде всего на `macro F1`, `balanced ассигасу` и полноту по отдельным классам.

Матрица ошибок используется для более подробного анализа. Ее элемент C_{ij} показывает, сколько объектов истинного класса i отнесено к классу j :

$$C_{ij} = |\{x_m : y_m = i, \hat{y}_m = j\}|. \quad (1.18)$$

Формула (1.18) позволяет увидеть, какие классы смешиваются между собой. Для данной работы особенно важны ошибки `both` $\rightarrow$ `crackle` и `both` $\rightarrow$ `wheeze`, потому что они означают, что модель распознала только один из двух типов событий.

Таким образом, метрики качества образуют несколько уровней анализа. Ассигасу показывает общую долю правильных ответов, weighted F1 учитывает естественное распределение классов, `macro F1` уравнивает вклад классов, `balanced ассигасу` анализирует среднюю полноту, а матрица ошибок показывает структуру неправильных решений. Только совместное

рассмотрение этих метрик позволяет корректно сравнивать архитектуры на несбалансированной медицинской аудиозадаче.

Precision и recall отражают разные типы ошибок. Низкая precision класса означает, что модель слишком часто относит к нему чужие фрагменты. Низкая recall означает, что модель пропускает реальные фрагменты этого класса. Для медицинской аудиоклассификации оба типа ошибок важны, но для редких патологических событий особенно критична полнота: если класс `both` почти не находится, высокая общая ассигасу теряет практический смысл.

Macro F1 выбран как одна из центральных метрик потому, что он уравнивает вклад классов. Каждый класс сначала оценивается отдельно, а затем значения усредняются. Поэтому улучшение только класса `normal` не может полностью скрыть деградацию `both`. Balanced ассигасу дополняет macro F1, поскольку напрямую показывает среднюю полноту. Если macro F1 низок из-за падения precision, а balanced ассигасу высока, модель может быть полезна как чувствительный детектор. Если balanced ассигасу низкая, значит часть классов систематически пропускается.

Weighted F1 интерпретируется осторожно. Он ближе к качеству на естественном распределении сегментов, но при сильном дисбалансе заметно зависит от класса `normal`. Поэтому weighted F1 используется как дополнительная характеристика, а не как единственный критерий выбора. В отчете отдельно рассматриваются per-class recall и графики по классам, чтобы показать, за счет каких классов формируется итоговая метрика.

Матрица ошибок важна еще и потому, что ошибки между классами имеют разную природу. Перепутать `crackle` и `both` означает, что модель, возможно, нашла короткие хрипы, но не выделила свистящий компонент. Перепутать `normal` и `wheeze` означает более грубую ошибку, при которой дополнительный дыхательный звук вообще не был отделен от нормы. Поэтому анализ метрик должен сопровождаться предметной интерпретацией структуры ошибок.

1.10 Экспериментальная постановка

Все модели используют одинаковые сегменты, одинаковое пациент-независимое разбиение и одинаковые целевые классы. Не-трансформерные

архитектуры используются как экспериментальные ориентиры качества. Для трансформерного подхода дополнительно проверяются несколько режимов обучения и принятия решения: взвешенная cross entropy, focal loss, нормализация по константам AudioSet, микс и калибровка логитов.

В практической главе сравниваются ручные признаки, сверточная модель, сверточно-рекуррентная модель и трансформерный подход. Такое сравнение показывает, насколько рост качества связан с переходом от простых признаков к локальным нейросетевым признакам, затем к временной агрегации и далее к самовниманию.

Для не-AST части используются три завершенных экспериментальных ориентира: MFCC + логистическая регрессия, ResNet18 на log-mel спектрограммах и CRNN GRU на log-mel спектрограммах. Эти модели выбраны потому, что они представляют разные уровни сложности: ручные признаки и линейный классификатор, сверточное извлечение локальных признаков и явное моделирование временной последовательности. Сопоставление с ними позволяет отделить вклад выбранной AST-архитектуры от эффекта общей предварительной обработки аудио.

Глава 2. Теоретическое описание выбранного решения

2.1 Общий конвейер AST-Base

Во второй главе рассматривается выбранная основная архитектура AST-Base. Теоретическое решение строится вокруг преобразования дыхательного аудиофрагмента в логарифмическую мел-спектрограмму и последующей классификации этой спектрограммы трансформерной моделью.

Полный конвейер обработки показан на рисунке 2.1. Он начинается с сырой аудиозаписи, затем выделяется размеченный дыхательный цикл, сигнал приводится к фиксированной длительности, строится логарифмическая мел-спектрограмма, после чего AST-Base выполняет классификацию одного из четырех классов.




Рис. 2.1: Конвейер классификации дыхательного аудиосегмента на основе AST-Base

Рисунок 2.1 отражает важное свойство реализации: модель не работает с исходным WAV-файлом напрямую. Входом AST является двумерное частотно-временное представление, поэтому качество всей системы зависит и от параметров предварительной обработки, и от параметров трансформерной части.

2.2 Выбор и описание набора данных

Для выбранного решения используется открытый набор дыхательных звуков ICBHI, подготовленный для задачи автоматического анализа респираторных звуков в рамках International Conference on Biomedical and Health Informatics Challenge и описанный в работе [1]. Набор был сформирован как единая база для сравнения алгоритмов классификации дыхатель-

ных звуков, поэтому он подходит для дипломной работы: данные доступны исследователям, имеют принятую в литературе разметку и позволяют сопоставлять разные архитектуры на одинаковых исходных аудиозаписях.

ICBNI содержит записи дыхания пациентов с различными респираторными состояниями. Для данной работы важна не постановка диагноза по пациенту, а классификация отдельных дыхательных циклов по наличию акустических событий. Поэтому из набора используется та часть информации, которая описывает временные границы циклов и бинарные признаки *crackle* и *wheeze*. Такая разметка естественно переводится в четыре класса: отсутствие дополнительных событий, наличие только коротких хрипов, наличие только свистящих хрипов и совместное наличие обоих типов событий.

Структура набора данных удобна для выбранной модели. Каждый аудиофайл хранится как отдельная WAV-запись, а соответствующий текстовый файл содержит последовательность размеченных дыхательных циклов. В строке разметки задаются начало и конец цикла в секундах, а также два бинарных индикатора. Благодаря этому исходная длительная запись может быть разбита на несколько самостоятельных объектов классификации. Такой формат соответствует медицинской природе задачи: врач при аускультации также анализирует отдельные фазы дыхания, а не только всю запись целиком.

С точки зрения данных ICBNI неоднороден. Записи получены от разных пациентов, различаются по длительности, уровню шума, устройству записи и положению датчика. Эта неоднородность важна для проверки устойчивости модели. Если бы все данные были записаны одним устройством в одинаковых условиях, итоговая модель могла бы переоценивать качество из-за слишком узкой области применения. Наличие разных условий записи усложняет обучение, но делает оценку более содержательной.

Для AST-Base особенно важно, что набор содержит не только итоговую метку записи, но и временную разметку дыхательных циклов. Трансформерная модель получает вход фиксированной длительности, поэтому предварительное выделение цикла уменьшает количество нерелевантных участков: пауз, переходов между циклами, шумов контакта и фрагментов, не связанных с целевым событием. Без такой разметки пришлось бы ре-

шать одновременно две задачи: найти информативный участок внутри записи и классифицировать его. В данной работе задача локализации не ставится, поэтому использование готовых границ циклов является теоретически оправданным.

При выборе данных также учитывался дисбаланс классов. Для дыхательных наборов естественно, что нормальные или одиночные события встречаются чаще, чем совместное наличие `crackle` и `wheeze`. Поэтому ICBNI подходит для проверки методов, устойчивых к несбалансированной классификации. Он позволяет оценить не только общую точность, но и способность модели распознавать редкие составные события. Это напрямую связано с выбором `macro F1`, `balanced accuracy`, взвешенной функции потерь и калибровки логитов.

Содержательно набор данных можно рассматривать как таблицу сегментов, полученную из исходных записей и файлов разметки. Каждая строка такой таблицы содержит ссылку на аудиофайл, начало и конец дыхательного цикла, идентификатор пациента, два бинарных признака событий и целевую метку. На рисунке 2.2 показана логическая структура данных, используемая выбранным решением.




Рис. 2.2: Логическая структура набора данных после выделения дыхательных циклов

Рисунок 2.2 подчеркивает, что единицей обучения является не исходный файл целиком, а сегмент дыхательного цикла. При этом идентификатор пациента сохраняется как служебный признак для корректного разби-

ения выборки. Он не передается модели как входной признак, поскольку цель состоит в распознавании акустического события, а не в запоминании пациента.

Выбор ICBNI также связан с воспроизводимостью. Для закрытых медицинских аудиоданных часто невозможно проверить результаты вне конкретной организации, а описание разметки может быть неполным. Открытый набор с опубликованным описанием снижает эту проблему: параметры предварительной обработки, правила формирования классов и метрики можно явно зафиксировать в отчете. Поэтому дальнейшее теоретическое описание AST-Base строится вокруг именно такого формата данных: размеченные дыхательные циклы, четыре класса, пациент-независимая оценка и несбалансированное распределение классов.

2.3 Входной аудиофрагмент и спектральное представление

Выбранное решение ориентировано не на классификацию всей исходной записи, а на классификацию отдельного размеченного дыхательного цикла. Такое ограничение важно для корректной постановки задачи. В исходной базе одна запись может содержать несколько циклов, разные паузы, шумы контакта микрофона и участки, не относящиеся к дыхательному событию. Если подавать в модель всю запись целиком, то один входной пример будет смешивать несколько акустических состояний и не будет однозначно соответствовать целевой метке. Поэтому на первом этапе используется разметка временных границ циклов, а каждый цикл рассматривается как самостоятельный объект классификации.

Для модели AST-Base требуется фиксированная форма входного тензора. Это требование связано не только с размером пакета при обучении, но и с позиционными вложениями трансформера. Последовательность токенов должна иметь ограниченную максимальную длину, иначе память GPU будет расходоваться квадратично по числу токенов в механизме самовнимания. Поэтому в работе выбран единый временной интервал 8 секунд. Он достаточно велик, чтобы вместить большинство дыхательных циклов, и одновременно не приводит к чрезмерному росту числа временных кадров в спектрограмме.

Преобразование к монофоническому сигналу также является частью

входного протокола. В задаче не используется пространственная информация между каналами, а исходные записи датасета рассматриваются как одномерные временные сигналы. Если запись содержит несколько каналов, они должны быть сведены к одному каналу до вычисления спектрограммы. В результате модель получает сопоставимые примеры, а различия между объектами определяются дыхательным событием, устройством записи, шумом и пациентом, но не произвольной конфигурацией каналов.

Нормализация частоты дискретизации к 16 кГц согласована с предварительно обученной AST-Base и с практическим диапазоном дыхательных звуков. Более высокая частота дискретизации увеличила бы объем вычислений и число спектральных отсчетов, но не дала бы прямого преимущества для большинства низко- и среднечастотных дыхательных паттернов. Более низкая частота могла бы привести к потере высокочастотных составляющих, которые полезны для распознавания коротких хрипов и шумовых компонентов. Поэтому 16 кГц используется как компромисс между сохранением информативного диапазона и вычислительной стоимостью.

Короткие циклы дополняются циклическим повторением, а длинные фрагменты обрезаются. Циклическое дополнение предпочтительнее простого заполнения нулями, потому что нулевые участки создают искусственные области тишины и меняют статистику log-mel спектрограммы. При повторении короткого цикла сохраняется его спектральная структура, хотя появляется риск усиления периодичности. Этот риск учитывается в третьей главе при анализе ошибок, поскольку часть неправильных ответов может быть связана не только с архитектурой, но и с процедурой приведения длительности.

Преобразование аудиосигнала.

Пусть $x[n]$ – дискретный монофонический сигнал, полученный после ресемплирования исходной записи к 16 кГц. Для выделенного дыхательного цикла выполняется приведение к фиксированной длине:

$$\tilde{x} = \text{FixLength}(x, 8 \cdot 16000), \quad (2.1)$$

где FixLength означает обрезание длинного фрагмента или циклическое дополнение короткого фрагмента. Формула (2.1) задает вход одинаковой длины для всех последующих операций.

Далее вычисляется кратковременное преобразование Фурье:

$$S(m, k) = \sum_{n=0}^{N-1} \tilde{x}[n + mh] w[n] e^{-j2\pi kn/N}, \quad (2.2)$$

где $w[n]$ – оконная функция, h – шаг окна, m – номер временного кадра, k – частотный индекс. В работе используется окно 25 мс и шаг 10 мс.

Спектр мощности проецируется на мел-шкалу и логарифмируется:

$$X = \log(M|S|^2 + \epsilon), \quad (2.3)$$

где M – матрица из 128 мел-фильтров, ϵ – малая константа для численной устойчивости. Затем выполняется нормализация:

$$X_{\text{norm}} = \frac{X - \mu_X}{\sigma_X + \epsilon}. \quad (2.4)$$

Формулы (2.2)–(2.4) задают входное представление AST-Base. Схематический вид такого представления приведен на рисунке 2.3.

Параметры предварительной обработки в работе выбраны так, чтобы сохранить локальные временные события и одновременно получить вход, совместимый с AST-Base. Основные значения приведены в таблице 2.1. Эта таблица связывает теоретические обозначения из формул (2.1)–(2.4) с конкретными параметрами практической реализации.

Таблица 2.1: Параметры формирования входной log-mel спектрограммы

Параметр	Значение	Назначение
Частота дискретизации	16 кГц	единый временной масштаб для всех записей
Длительность фрагмента	8 с	фиксированная длина входа модели
Окно STFT	25 мс	локальная оценка спектрального состава
Шаг STFT	10 мс	сохранение временной детализации событий
Число mel-каналов	128	компактное частотное представление
Максимальная длина AST	1024 кадра	ограничение длины входной последовательности

Окно 25 мс задает локальный участок, внутри которого сигнал считается достаточно стационарным для спектрального анализа. Для дыхательных звуков это приближение не является точным во всех случаях, но оно практически удобно: окно достаточно короткое, чтобы фиксировать кратковременные изменения, и достаточно длинное, чтобы получить устойчивую оценку спектра. Шаг 10 мс дает перекрытие соседних окон и снижает риск пропуска коротких событий между кадрами.

Использование 128 mel-каналов задает вертикальное разрешение спектрограммы. При меньшем числе каналов модель получила бы более грубое частотное описание, что особенно нежелательно для протяженных тональных компонентов класса wheeze. При существенно большем числе каналов увеличивался бы размер входа без гарантии роста качества, потому что объем обучающей выборки ограничен. Поэтому выбранное значение является практическим компромиссом между детализацией и устойчивостью обучения.

Логарифмирование энергии в формуле (2.3) уменьшает динамический диапазон признаков. Без этой операции сильные компоненты спектра могли бы доминировать над слабыми, а короткие дыхательные события терялись бы на фоне общей энергии записи. После логарифмирования раз-

личия становятся ближе к масштабу, в котором их удобнее обрабатывать линейными проекциями и механизмом внимания. Последующая нормализация в формуле (2.4) приводит вход к более стабильному распределению и уменьшает зависимость обучения от абсолютной громкости записи.




Рис. 2.3: Схематическое частотно-временное представление дыхательного фрагмента после log-mel преобразования

На рисунке 2.3 показана не конкретная запись из датасета, а схема распределения энергии во времени и по мел-каналам. Для дыхательных событий важны как короткие локальные всплески, характерные для *crackle*, так и более протяженные частотные области, характерные для *wheeze*.

2.4 Акустические признаки целевых классов

Четыре класса задачи различаются не только меткой, но и типом частотно-временного рисунка. Класс *normal* соответствует сегментам без размеченных дополнительных событий. Его спектрограмма обычно не содержит ярко выраженных коротких всплесков или устойчивых узкополосных участков. При этом нормальный класс не является полностью однородным: громкость, фаза дыхания, положение микрофона и пациентские различия могут сильно менять общий вид спектрограммы.

Класс *crackle* связан с короткими дискретными событиями. В log-mel представлении такие события проявляются как локальные всплески энергии, которые могут занимать небольшое число временных кадров. Для распознавания этого класса важна временная детализация, поэтому шаг STFT и патчевое разбиение не должны чрезмерно сглаживать сигнал. Если короткое событие попадает на границу патча, модель должна восстановить его значение через соседние токены и последующее самовнимание.

Класс `wheeze` имеет другую природу: он чаще представлен более протяженными тональными компонентами. В спектрограмме такие компоненты выглядят как относительно устойчивые частотные области на протяжении части дыхательного цикла. Для этого класса важна способность модели связывать удаленные временные участки и оценивать длительность паттерна. Именно здесь полезен механизм самовнимания, потому что он может сопоставлять разные части спектрограммы без последовательного накопления контекста.

Класс `both` объединяет признаки `crackle` и `wheeze`. Он сложен по двум причинам. Во-первых, это редкий класс, поэтому модель получает меньше разнообразных примеров. Во-вторых, он не описывается одним простым акустическим шаблоном: короткие всплески и протяженные тональные компоненты могут находиться в разных местах дыхательного цикла и иметь разную интенсивность. Для такой метки особенно важно, чтобы классификатор не сводил решение только к самому сильному локальному признаку.

Из этого следует, что выбранная архитектура должна одновременно учитывать локальные и глобальные свойства спектрограммы. Локальные свойства нужны для коротких событий, глобальные — для оценки распределения энергии по всему дыхательному циклу и для совместного анализа разных типов признаков. AST-Base удовлетворяет этому требованию за счет `patch embedding`, который выделяет локальные участки, и `self-attention`, который связывает их в единую последовательность.

2.5 Патчи спектрограммы и вход трансформера

AST-Base рассматривает нормализованную спектрограмму как двумерную сетку, которая разбивается на патчи. Каждый патч разворачивается в вектор и линейно проецируется в пространство скрытой размерности:

$$z_i = W_p \text{vec}(P_i) + b_p, \quad (2.5)$$

где P_i — i -й патч спектрограммы, W_p и b_p — параметры линейного слоя `patch embedding`. Формула (2.5) переводит локальный участок спектрограммы в токен трансформера.

К последовательности токенов добавляется специальный классифи-

кационный токeн и позиционные вложения:

$$Z_0 = [z_{cls}; z_1; z_2; \dots; z_N] + E_{pos}. \quad (2.6)$$

Выражение (2.6) важно, потому что без позиционных вложений модель не различала бы порядок патчей по времени и частоте. Схема формирования входной последовательности показана на рисунке 2.4.




Рис. 2.4: Разбиение log-mel спектрограммы на патчи и формирование последовательности токенов AST

Рисунок 2.4 показывает, что каждый токен соответствует локальному частотно-временному участку. При этом дальнейший механизм самовнимания позволяет каждому токeну учитывать информацию из остальных участков спектрограммы.

Патчевое представление является переходом от аудиозадачи к задаче обработки последовательности. AST-Base не накладывает жесткое предположение, что информация должна распространяться только через локальные соседства. После формирования токенов любой участок спектрограммы может быть связан с любым другим участком уже в одном слое внимания. Это особенно важно для дыхательных циклов, где события могут располагаться в начале, середине или конце фрагмента.

Позиционные вложения в формуле (2.6) выполняют две функции. Во-первых, они задают временной порядок патчей, без которого модель не отличала бы ранний участок дыхательного цикла от позднего. Во-вторых, они задают частотное положение, что необходимо для различения низко- и высокочастотных компонентов. Для дыхательных звуков это существенно, потому что разные типы событий могут занимать разные диапазоны mel-каналов.

Предварительно обученная AST-Base была получена на общей зада-

че аудиоклассификации [2]. Поэтому ее patch embedding и позиционные представления уже содержат полезное приближение к обработке спектрограмм. Однако вход в текущей задаче имеет собственную длительность и собственное распределение энергии. При дообучении модель адаптирует параметры так, чтобы токены дыхательных спектрограмм давали разделимые представления четырех целевых классов. Это не отменяет пользы предварительного обучения, но делает его начальной точкой, а не финальным решением.

Максимальная длина входа AST ограничена 1024 временными позициями. При длительности 8 секунд и шаге 10 мс фактическое число кадров остается внутри этого предела. Если бы длительность была существенно увеличена, пришлось бы либо усекать спектрограмму, либо менять конфигурацию модели, либо использовать агрегацию фрагментов. В данной работе такие усложнения не вводятся, потому что цель состоит в сравнительно простой и воспроизводимой схеме дообучения выбранной архитектуры.

Блок самовнимания.

Основной вычислительный блок AST-Base состоит из нормализации, многоголового самовнимания, остаточного соединения и полносвязной MLP-части. Для входной последовательности Z строятся матрицы запросов, ключей и значений:

$$Q = ZW_Q, \quad K = ZW_K, \quad V = ZW_V. \quad (2.7)$$

Механизм внимания вычисляется по формуле:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d}} \right) V. \quad (2.8)$$

Формулы (2.7) и (2.8) описывают, как модель оценивает связи между всеми патчами спектрограммы.

Один блок трансформера задается выражениями:

$$Z'_l = Z_{l-1} + \text{MHSA}(\text{LN}(Z_{l-1})), \quad (2.9)$$

$$Z_l = Z'_l + \text{MLP}(\text{LN}(Z'_l)). \quad (2.10)$$

Структура блока показана на рисунке 2.5. Остаточные соединения в формулах (2.9) и (2.10) помогают сохранять исходную информацию токена и стабилизируют обучение глубокой модели.




Рис. 2.5: Структура блока трансформера в AST-Base

Рисунок 2.5 иллюстрирует, что блок не только смешивает информацию между токенами через самовнимание, но и нелинейно преобразует каждый токен через MLP. За счет повторения таких блоков AST-Base формирует глобальное представление дыхательного фрагмента.

Многоголовое внимание расширяет формулу (2.8): вместо одной матрицы внимания вычисляется несколько параллельных голов. Каждая голова имеет собственные проекции W_Q , W_K и W_V , поэтому может выделять разные типы связей между токенами. Одна голова может быть полезна для локальных соседних участков, другая – для повторяющихся временных паттернов, третья – для сопоставления частотных областей. После этого результаты голов объединяются и снова проецируются в скрытое пространство модели.

Для дыхательных спектрограмм такая схема имеет практический

смысл. Если короткий `crackle` выражен только в нескольких кадрах, он может быть слабым относительно общего дыхательного шума. Механизм внимания позволяет классификационному токenu усилить вклад этих кадров, если они статистически важны для метки. Если же присутствует `wheeze`, модель может учитывать длительный участок спектрограммы и не ограничиваться одним локальным максимумом энергии.

LayerNorm в формулах (2.9) и (2.10) стабилизирует распределение скрытых состояний. Это важно при полном дообучении pretrained-модели, потому что входная область дыхательных звуков уже отличается от исходной области AudioSet. Остаточные соединения позволяют не разрушать полезные признаки, полученные на ранних слоях, и уменьшают риск деградации представления при прохождении через глубокую последовательность блоков.

MLP-часть блока выполняет нелинейное преобразование каждого токена после обмена информацией через внимание. Если самовнимание отвечает за смешивание контекста, то MLP уточняет признаки внутри каждого положения последовательности. В результате один слой трансформера можно рассматривать как две последовательные операции: сначала модель решает, какие токены должны взаимодействовать, затем преобразует обновленные токены в более подходящее пространство признаков.

2.6 Перенос обучения и классификационная голова

AST-Base была предложена как трансформерная модель для классификации аудио по спектрограммам [2]. Ее практическая ценность в данной работе связана с переносом обучения: модель уже обучалась на большом наборе разнообразных аудиособытий AudioSet [8]. Это позволяет не начинать обучение с случайных признаков, что особенно важно при ограниченном числе размеченных дыхательных циклов.

Перенос обучения используется в виде полной замены классификационной головы и последующего дообучения всех параметров. Замена головы необходима, потому что исходный checkpoint решает задачу с другим набором классов. Новая голова получает четыре выхода, соответствующие классам `normal`, `crackle`, `wheeze` и `both`. Остальные параметры инициализируются из pretrained checkpoint, поэтому модель начинает обуче-

ние с уже сформированным спектральным представлением.

Альтернативой было бы заморозить backbone и обучать только классификационную голову. Такой режим дешевле и снижает риск переобучения, но он ограничивает адаптацию к дыхательным сигналам. В данной работе backbone не замораживается, поскольку акустическая область отличается от общей аудиоклассификации: дыхательные события слабее, короче и чаще зависят от условий записи. Полное дообучение позволяет менять не только финальную линейную границу классов, но и сами признаки, на которых строится это разделение.

При этом полное дообучение требует осторожного learning rate. Слишком большой шаг оптимизатора мог бы быстро разрушить pretrained-представления, а слишком маленький привел бы к слабой адаптации. Поэтому используется значение $5 \cdot 10^{-5}$, характерное для аккуратного fine-tuning трансформерных моделей. Weight decay ограничивает рост весов и работает как регуляризация, что полезно при небольшой и несбалансированной выборке.

Выбранный подход можно описать как domain-specific fine-tuning. Общие аудиопризнаки используются как начальное знание, но итоговая модель оптимизируется под конкретное распределение дыхательных циклов. Это соответствует практической цели работы: не доказать универсальность AST для любых аудиозадач, а получить воспроизводимую модель для заданной четырехклассовой классификации.

Классификационная голова.

После последнего блока трансформера используется представление классификационного токена $z_{\text{cls}}^{(L)}$. На его основе вычисляются логиты четырех классов:

$$o = W_c \text{LN}(z_{\text{cls}}^{(L)}) + b_c, \quad (2.11)$$

$$\hat{p} = \text{softmax}(o). \quad (2.12)$$

Формулы (2.11) и (2.12) задают финальную классификационную часть модели.

В реализации используется предварительно обученный checkpoint AST-Base, дообученный на AudioSet. Его исходная классификационная голова, обученная на AudioSet-классах [8], заменяется новой головой на

четыре класса дыхательных событий. При этом остальная часть AST-Base дообучается полностью, то есть параметры backbone не замораживаются.

Причина выбора полного дообучения состоит в том, что дыхательные записи отличаются от общей аудиоклассификации. Предварительное обучение дает полезные низко- и среднеуровневые признаки спектрограмм, но модель должна адаптировать распределение внимания и итоговое представление к коротким дыхательным событиям. Ограничение по размеру модели соблюдается: выбранная AST-Base содержит 86м параметров, что меньше 100 млн.

Классификационный токен используется как агрегированное представление всего фрагмента. В отличие от усреднения всех патчей, такой подход позволяет модели обучить специальный токен, который собирает информацию, наиболее полезную для классификации. Через слои самовнимания этот токен взаимодействует с патчами спектрограммы и постепенно накапливает сведения о локальных и глобальных признаках.

Финальная softmax-вероятность в формуле (2.12) используется для выбора наиболее вероятного класса, однако при анализе качества важны не только максимальные вероятности. Если модель часто путает `both` с `crackle` или `wheeze`, то такая ошибка может быть скрыта в общей ассигасу, но проявится в `per-class recall` и `macro F1`. Поэтому теоретическое описание классификационной головы напрямую связано с выбором метрик в третьей главе.

2.7 Функция потерь и учет дисбаланса

В обучающей выборке классы распределены неравномерно: `normal` представлен 16568 сегментами, а `both` – только 589 сегментами. Поэтому используется взвешенная перекрестная энтропия:

$$L = -\frac{1}{B} \sum_{i=1}^B w_{y_i} \log \hat{p}_{i,y_i}, \quad (2.13)$$

где B – размер пакета, w_{y_i} – вес класса, обратно пропорциональный его частоте. Формула (2.13) увеличивает вклад ошибок на редких классах.

Дополнительно применяется взвешенная выборка. Для каждого обучающего примера задается вероятность попадания в пакет, связанная с ве-

сом его класса. Поэтому редкие классы чаще появляются во время обучения, а модель получает больше градиентных шагов, связанных с wheeze и both. Совместная схема учета дисбаланса показана на рисунке 2.6.




Рис. 2.6: Учет дисбаланса классов при обучении AST-Base

Рисунок 2.6 показывает, что веса классов используются в двух местах: при формировании обучающих пакетов и при вычислении функции потерь. Такая схема не устраняет дисбаланс полностью, но повышает внимание модели к редким классам.

Использование только `weighted sampler` без взвешенной функции потерь изменило бы состав пакетов, но не изменило бы цену ошибки внутри конкретного пакета. Использование только `weighted loss`, наоборот, усилило бы градиент от редких классов, но редкие примеры появлялись бы в обучении реже. Совместное применение двух механизмов делает обучение более направленным на `minority`-классы, хотя и может повысить нестабильность метрик на валидации.

Особенно важен класс `both`. Его редкость означает, что модель может получить приемлемый `weighted F1` даже при слабом качестве этого класса, если хорошо распознает `normal`. Поэтому `macro F1` используется не только как отчетная метрика, но и как критерий выбора лучшего `checkpoint`. Такой выбор согласован с целью получить модель, которая не игнорирует малочисленные классы.

Регуляризация и аугментации спектрограмм.

Для аудиозадач регуляризация может выполняться как на уровне исходного сигнала, так и на уровне спектрограммы. В данной работе основная теоретическая схема допускает использование спектрограммных ауг-

ментаций, близких к SpecAugment [6]: маскирование временных и частотных областей. Такие преобразования не меняют целевую метку, но заставляют модель опираться не на один узкий участок, а на более устойчивое распределение признаков.

Временное маскирование скрывает часть кадров спектрограммы. Для класса `wheeze` это может предотвращать ситуацию, когда модель запоминает один конкретный временной участок вместо общего протяженного паттерна. Для класса `crackle` маскирование требует осторожности: если скрыть единственный короткий всплеск, пример может стать неоднозначным. Поэтому агрессивность временных масок должна быть ограниченной.

Частотное маскирование скрывает часть `mel`-каналов. Оно полезно против переобучения на конкретный частотный профиль устройства записи или пациента. Если модель видит один и тот же класс при частично скрытых частотах, она учится использовать более широкий контекст. Однако слишком широкие частотные маски могут повредить распознаванию `wheeze`, поскольку этот класс часто связан с выраженными частотными полосами.

Weight decay в оптимизаторе AdamW является параметрической регуляризацией. Он не меняет входные данные, но ограничивает величину весов и снижает склонность модели к запоминанию обучающей выборки. Для AST-Base это особенно важно из-за большого числа параметров: 86м параметров существенно больше, чем число уникальных пациентов и дыхательных циклов в используемой выборке.

Еще одним источником регуляризации является выбор лучшего checkpoint по валидационной макро F1, а не по минимальному train loss. Если модель начинает переобучаться, train loss может продолжать снижаться, но качество на валидации перестает расти. Поэтому критерий сохранения checkpoint фактически ограничивает использование переобученных состояний модели.

2.8 Организация обучения, валидации и ограничения

Обучающая, валидационная и тестовая части формируются с учетом patient-independent split. Это означает, что циклы одного пациента не долж-

ны одновременно попадать в обучение и оценку. Такое правило важнее случайного разбиения по отдельным сегментам, потому что дыхательные записи одного пациента могут иметь общие свойства: устройство, условия записи, тембр дыхания, уровень шума и повторяющиеся паттерны.

Если игнорировать patient-independent split, модель могла бы частично узнавать пациента, а не обобщать признаки класса. В этом случае оценка на валидации была бы завышенной и хуже отражала бы работу на новых пациентах. Поэтому теоретически корректная валидация должна отделять не только файлы, но и источники записей. В данной работе это условие задано в конфигурации разбиения данных.

Размер пакета 8 выбран с учетом памяти GPU и размера AST-Base. Для трансформеров память зависит от числа токенов и числа слоев, а механизм внимания имеет квадратичную сложность по длине последовательности. Увеличение batch size могло бы стабилизировать градиенты, но потребовало бы больше памяти. Уменьшение batch size сделало бы обучение более шумным. Поэтому выбранное значение является практическим компромиссом.

Обучение AST-Base проводится 25 эпох. Это число задает верхнюю границу процесса, но итоговая модель выбирается не по последней эпохе, а по лучшему значению макро F1 на валидации. Такой подход важен для больших pretrained-моделей: после некоторого момента дальнейшее обучение может улучшать подгонку train-выборки, но ухудшать способность к обобщению.

Для воспроизводимости фиксируется seed 42. Полная битовая воспроизводимость в GPU-обучении не всегда гарантируется из-за недетерминированных операций, но фиксированный seed уменьшает разброс, связанный с начальным порядком данных и стохастическими компонентами обучения. В отчете это важно для интерпретации результатов: сравнение моделей должно отражать архитектурные различия, а не случайные особенности одного запуска.

Параметры обучения и ограничения.

AST-Base обучается 25 эпох с размером пакета 8. Оптимизатор AdamW использует learning rate $5 \cdot 10^{-5}$ и weight decay 10^{-4} . Лучший checkpoint выбирается по макро F1 на валидационной выборке, поскольку

ку эта метрика не позволяет большинству класса `normal` полностью доминировать при выборе модели.

Основные ограничения выбранного решения связаны с предварительной обработкой, шумом и редкими классами. Длина 8 секунд удобна для единого входа, но короткие дыхательные циклы приходится повторять циклическим дополнением. Разные устройства записи могут менять спектральный профиль сигнала. Наконец, класс `both` остается самым трудным, поскольку он редко встречается и объединяет признаки двух разных акустических событий.

Вычислительная сложность AST-Base определяется не только числом параметров, но и длиной токеной последовательности. Для каждого слоя `attention` необходимо вычислить матрицу попарных взаимодействий между токенами. Поэтому увеличение длительности аудио или уменьшение шага STFT напрямую повышает стоимость обучения. В выбранной конфигурации длительность 8 секунд, шаг 10 мс и ограничение 1024 кадра удерживают задачу в пределах доступной памяти.

Еще одно ограничение связано с интерпретируемостью. Attention-карты могут показать, какие области спектрограммы получили высокий вес, но они не являются полноценным объяснением решения модели. Высокое внимание к определенному патчу не всегда означает причинную важность этого участка. Поэтому в практической части основная оценка строится на метриках качества и матрице ошибок, а не на визуальной интерпретации `attention`.

Наконец, выбранное решение зависит от качества разметки. Если границы дыхательного цикла заданы неточно, в 8-секундный фрагмент может попасть лишняя пауза или часть соседнего события. Если метка класса неоднозначна, модель получает противоречивый обучающий сигнал. Архитектура AST-Base не устраняет эти проблемы автоматически; она только дает более выразительный механизм обработки спектрограмм. Поэтому качество итоговой системы ограничивается не только моделью, но и исходной разметкой, процедурой сегментации и репрезентативностью выборки.

2.9 Обоснование выбора AST-Base

Выбор AST-Base как основной архитектуры связан с тремя требованиями задачи. Во-первых, модель должна сохранять локальные признаки, поскольку crackle может занимать лишь несколько временных кадров. Во-вторых, модель должна учитывать глобальный контекст дыхательного цикла, поскольку wheeze и класс both могут определяться распределением признаков по значительной части фрагмента. В-третьих, модель должна быть применима при ограниченном объеме размеченных медицинских аудиоданных. AST-Base удовлетворяет этим требованиям за счет патчowego представления, самовнимания и предварительного обучения на большой аудиоколлекции.

Сверточные модели хорошо выделяют локальные паттерны, но их глобальный контекст формируется через последовательность локальных операций. Рекуррентные модели учитывают порядок кадров, но передают дальнюю информацию через скрытое состояние. AST-Base использует другой принцип: после разбиения спектрограммы на патчи любой токен может взаимодействовать с любым другим токеном через матрицу внимания. Поэтому модель не обязана постепенно переносить информацию через соседние области. Для дыхательного фрагмента это означает, что короткий всплеск в начале цикла и протяженный тональный компонент в конце цикла могут быть сопоставлены напрямую.

Важен и характер входного представления. AST-Base не обрабатывает исходную волну напрямую, а получает log-mel спектрограмму. Это снижает размерность входа и переводит задачу в частотно-временную область, где целевые события имеют более явную структуру. Для медицинского аудио такой компромисс оправдан: исходный сигнал содержит много низкоуровневых колебаний, а log-mel представление выделяет энергетические закономерности, более связанные с типом дыхательного события.

Предварительное обучение является отдельным аргументом в пользу AST-Base. Большая трансформерная модель, обучаемая с нуля на ограниченной выборке дыхательных циклов, может переобучаться и нестабильно распознавать редкие классы. Pretrained AST уже содержит признаки, полезные для аудиособытий в целом: устойчивые спектральные шаблоны, реакции на временные изменения, частотные комбинации. Дообучение пе-

реносит эти признаки в более узкую область дыхательных звуков.

Теоретическая роль предварительного обучения.

Предварительное обучение можно рассматривать как задание начальной точки оптимизации. Пусть θ_0 – параметры AST-Base после обучения на внешней аудиозадаче, а θ^* – параметры после адаптации к дыхательным сегментам. Тогда fine-tuning ищет решение не в произвольной области пространства параметров, а в окрестности уже полезного аудиопредставления:

$$\theta^* = \theta_0 + \Delta\theta. \quad (2.14)$$

Формула (2.14) показывает, что дообучение изменяет pretrained-модель, но не начинает построение признаков с нуля.

Для малых и средних медицинских наборов данных это существенно. Если параметры инициализируются случайно, модель должна одновременно научиться базовой обработке спектрограмм и разделению целевых классов. При предварительном обучении первая часть уже частично решена. Поэтому ограниченный набор дыхательных циклов используется прежде всего для адаптации признаков и классификационной границы.

Перенос обучения не гарантирует автоматического улучшения. Внешняя аудиозадача и дыхательная классификация различаются по распределению сигналов, типам событий и уровню шума. Поэтому требуется полное дообучение, а не только замена финального слоя. Если оставить backbone неизменным, модель сможет изменить лишь линейную комбинацию уже существующих признаков. При полном fine-tuning изменяются и ранние, и поздние представления, что позволяет адаптировать внимание к слабым дыхательным компонентам.

Однако полное дообучение увеличивает риск переобучения. Поэтому выбранная схема должна сочетать pretrained initialization, умеренный learning rate, weight decay и выбор checkpoint по валидационной macro F1. Эти элементы не являются независимыми деталями: вместе они задают режим, при котором модель может адаптироваться к новой области, но не должна разрушать ранее выученные аудиопризнаки.

Роль нормализации и масштаба признаков.

Log-mel спектрограмма содержит значения энергии, зависящие от громкости записи, расстояния до датчика и условий записи. Если не нор-

мализовать вход, модель может использовать абсолютный уровень сигнала как ложный признак класса. Это особенно опасно в *patient-independent* постановке: некоторые пациенты или устройства могут быть связаны с определенными классами, и модель будет запоминать условия записи вместо дыхательных событий.

Нормализация уменьшает влияние таких факторов. При посегментной нормализации каждый фрагмент приводится к сопоставимому масштабу, что усиливает относительные частотно-временные различия. При нормализации по внешним константам сохраняется больше информации об абсолютной энергии, но возникает зависимость от того, насколько распределение дыхательных спектрограмм похоже на распределение данных предварительного обучения. Теоретически оба варианта имеют смысл, поэтому их сравнение относится к важным аспектам выбранного решения.

Для класса *crackle* полезно сохранить локальные всплески относительно фона конкретного цикла. Для класса *wheeze* важна устойчивость частотной полосы во времени. Нормализация не должна уничтожать эти различия. Поэтому она рассматривается не как формальная техническая операция, а как часть модели входного представления.

Баланс между локальными и глобальными признаками.

Дыхательные события имеют разный масштаб. Короткие хрипы требуют высокой временной чувствительности, а свистящие компоненты требуют анализа протяженной структуры. *AST-Base* объединяет эти уровни через патчи и самовнимание. Патч задает локальную область спектрограммы, внутри которой сохраняются частотно-временные признаки. Самовнимание затем определяет, какие патчи важны совместно.

Такую схему можно описать как двухуровневую агрегацию. На первом уровне *patch embedding* преобразует локальные участки в токены. На втором уровне *transformer*-блоки строят связи между токенами. Если в спектрограмме есть несколько слабых признаков одного класса, модель может усилить их совместный вклад. Если же присутствует один яркий, но нерелевантный шумовой всплеск, глобальный контекст может снизить его влияние.

Для класса *both* это особенно важно. Такой фрагмент не обязан содержать идеально выраженные признаки обоих событий. Один компонент

может быть слабым или занимать малую часть времени. Модель, ориентированная только на самый сильный локальный признак, может отнести такой пример к `crackle` или `wheeze`. AST-Base теоретически позволяет учитывать несколько областей спектрограммы одновременно, что делает ее подходящей для составного класса.

Калибровка правила принятия решения.

Классификационная модель выдает логиты, но итоговое качество зависит не только от признакового представления, а также от правила принятия решения. В несбалансированной задаче стандартный выбор максимального softmax-значения может быть смещен в сторону частых классов. Это происходит даже тогда, когда модель научилась выделять признаки редкого класса: логиты редкого класса могут систематически уступать логитам более частых классов.

Теоретически это можно представить как добавление вектора смещений b к логитам:

$$\hat{y} = \arg \max_k (o_k + b_k). \quad (2.15)$$

Формула (2.15) не изменяет внутренние признаки модели, но меняет границы принятия решения между классами. Если смещение подбирается по валидационной выборке, оно может компенсировать систематический перекос в сторону большинства.

Калибровка особенно важна, когда разные метрики задают разные предпочтения. Ассигасу часто благоприятствует классу `normal`, `balanced` ассигасу требует высокой полноты каждого класса, `macro F1` учитывает баланс `precision` и `recall`. Поэтому один и тот же `backbone` может иметь несколько допустимых операционных точек. В выбранном решении основной интерес представляет точка, в которой редкий класс `both` не подавляется частыми классами, но общая `macro F1` остается высокой.

Калибровка не заменяет обучение модели. Если признаки не разделяют классы, изменение смещений не создаст новую информацию. Однако при наличии достаточно информативных логитов она может существенно изменить распределение ошибок. Поэтому калибровка рассматривается как теоретически оправданное завершение выбранного решения для несбалансированной четырехклассовой задачи.

Таким образом, глава описывает выбранное решение как полный

конвейер: от нормализации входного аудио и построения log-mel спектрограммы до patch embedding, самовнимания, классификационной головы и процедуры fine-tuning. Практическая глава далее проверяет, насколько такая теоретическая схема реализуется в метриках на валидационной и тестовой выборках.

Глава 3. Практическая реализация и анализ результатов

3.1 Среда и подготовка данных

Практическая часть реализована на Python 3.11. Для обучения AST-моделей используются PyTorch, torchaudio и библиотека transformers. Для загрузки и ресемплирования аудио применяются soundfile и librosa. Для расчета метрик используется scikit-learn, для построения матриц ошибок и кривых обучения – matplotlib и seaborn.

Обучение выполнялось на вычислительной машине с одной видеокартой NVIDIA H100. Такая конфигурация позволяет дообучать AST-Base с размером пакета 8 и фиксированной длительностью входного сегмента 8 секунд. Итоговая AST-Base содержит около 86 млн параметров и укладывается в ограничение 100 млн параметров.

Для каждого WAV-файла набора ICBHI используется одноименный TXT-файл с разметкой дыхательных циклов. Каждая строка разметки содержит начало, окончание и два бинарных признака наличия crackle и wheeze. По этим признакам формируется один из четырех классов.

Разбиение на обучающую, валидационную и тестовую выборки выполняется пациент-независимо. Используемые параметры подготовки данных приведены в таблице 3.1.

Таблица 3.1: Параметры подготовки данных

Параметр	Значение
Частота дискретизации	16000 Гц
Фиксированная длительность сегмента	8 с
Число мел-каналов	128
Окно STFT	25 мс
Шаг STFT	10 мс
Разбиение	70% / 15% / 15%
Тип разбиения	пациент-независимое

После обновления индексной таблицы получено 31185 сегментов. Распределение сегментов по выборкам приведено в таблице 3.2.

Таблица 3.2: Распределение сегментов по выборкам

Выборка	Число сегментов
Обучающая	23181
Валидационная	3947
Тестовая	4057
Итого	31185

Распределение классов в обучающей и тестовой выборках приведено в таблице 3.3. Класс `both` остается самым редким: в обучающей выборке он представлен 589 сегментами против 16568 сегментов класса `normal`.

Таблица 3.3: Распределение классов в обучающей и тестовой выборках

Класс	Обучающая выборка	Тестовая выборка
<code>normal</code>	16568	2918
<code>crackle</code>	4196	643
<code>wheeze</code>	1828	392
<code>both</code>	589	104

Дисбаланс классов дополнительно показан на рисунке 3.1. Видно, что класс `normal` доминирует и в обучающей, и в тестовой выборках. Класс `both`, напротив, представлен наименьшим числом примеров. Такое распределение объясняет, почему простая ассигасу не может быть основной метрикой качества: модель может часто угадывать `normal`, но при этом почти не находить редкие составные события.




Рис. 3.1: Распределение классов в обучающей и тестовой выборках

3.2 Практическая работа с данными перед обучением

Перед обучением моделей исходные файлы ICBNI были приведены к единому табличному представлению. Для каждой WAV-записи использовался соответствующий файл разметки. Из каждой строки разметки извлекались начало и конец дыхательного цикла, два бинарных признака `crackle` и `wheeze`, а также идентификатор пациента, получаемый из имени записи. После этого по правилу из формулы (1.2) формировалась целевая метка одного из четырех классов.

Практический смысл индексной таблицы состоит в том, что она отделяет этап чтения медицинской разметки от этапа обучения модели. После формирования таблицы каждый объект выборки однозначно задается набором полей: путь к аудиозаписи, временной интервал цикла, пациент, два исходных индикатора событий и итоговый класс. Такое представление уменьшает риск несогласованности между разными экспериментами: MFCC, ResNet18, CRNN GRU и AST получают один и тот же список сегментов и отличаются только способом построения признаков и классификации.

Схема практической подготовки данных показана на рисунке 3.2. Она начинается с чтения пары WAV/TXT, затем выполняется нарезка дыхательных циклов, формирование меток, пациент-независимое разбиение и построение входного представления для конкретной модели.




Рис. 3.2: Практический конвейер подготовки данных перед обучением

Особое внимание уделялось пациент-независимому разбиению. Разделение выполнялось не по отдельным сегментам, а по идентификаторам пациентов. Это означает, что все дыхательные циклы одного пациента попадали только в одну из трех выборок: обучающую, валидационную или тестовую. Такой подход уменьшает утечку информации, поскольку записи одного пациента могут иметь общий шумовой профиль, одинаковое устройство записи и близкую амплитудную характеристику. Если бы циклы одного пациента одновременно оказались в train и test, модель могла бы частично запоминать источник записи.

После разбиения проверялось распределение классов. Данные не балансировались путем удаления объектов большинства, потому что это уменьшило бы и без того ограниченный объем медицинской выборки. Вместо этого дисбаланс учитывался на уровне обучения и оценки: для AST применялись *weighted sampler*, взвешенная функция потерь или *focal loss*, а итоговые выводы строились по *macro F1*, *balanced accuracy* и полноте отдельных классов. Таким образом, естественное распределение данных сохранялось, но редкие классы не исчезали из критерия качества.

Для нейросетевых моделей каждый сегмент загружался из исходной записи по временным границам цикла. Затем сигнал приводился к монофоническому виду, ресемплировался к 16 кГц и нормализовался по длительности до 8 секунд. Короткие циклы дополнялись повторением, а слишком длинные обрезались. После этого для ResNet18, CRNN GRU и AST вычислялась log-mel спектрограмма с 128 mel-каналами, окном 25 мс и шагом 10 мс. Для MFCC-подхода из того же сегмента извлекались ручные спек-

тральные признаки.

Практическая подготовка данных также включала контроль неоднозначных случаев. Если дыхательный цикл очень короткий, его повторение может усилить периодичность и сделать пример менее похожим на естественную запись. Если цикл близок к границе соседнего события, в сегмент может попасть часть другого акустического паттерна. Эти случаи не удалялись вручную, поскольку целью было сохранить воспроизводимую процедуру подготовки, но их влияние учитывалось при анализе ошибок и при выборе метрик, устойчивых к шумной разметке.

Итогом этапа подготовки является единая тестовая выборка из 4057 сегментов, на которой сравниваются все подходы. Это важно для интерпретации результатов: различия в таблицах метрик далее связаны с архитектурой и режимом обучения, а не с разными наборами тестовых объектов. Поэтому практическая часть сначала фиксирует данные, разбиение и преобразования, а уже затем переходит к сравнению AST и не-AST подходов.

3.3 Исследованные AST-настройки

В практической части рассматривались несколько вариантов обучения AST-Base. Все они используют логарифмические мел-спектрограммы, предварительно обученный backbone и новую классификационную голову на четыре класса. Различия между вариантами связаны с функцией потерь, нормализацией признаков, регуляризацией и калибровкой выходных логитов.

Смысл такого набора экспериментов состоит в проверке нескольких гипотез. Взвешенная cross entropy проверяет базовый способ учета дисбаланса. Focal loss проверяет, помогает ли усиление трудных примеров. Mixup проверяет устойчивость к регуляризации входных спектрограмм. Нормализация по константам AudioSet проверяет совместимость входных признаков с областью предварительного обучения. Калибровка логитов проверяет, можно ли улучшить баланс классов без повторного обучения backbone. Сводка конфигураций приведена в таблице 3.4.

Таблица 3.4: Исследованные варианты AST-Base

Вариант	Ключевое отличие
AST focal + calibration	focal loss с $\gamma = 2.0$, weighted sampler, затем class-specific logit bias по validation balanced accuracy
AST focal $\gamma = 2.0$	focal loss с $\gamma = 2.0$ и weighted sampler
AST focal + mixup	focal loss с $\gamma = 2.0$, weighted sampler и mixup $\alpha = 0.2$
AST focal + AudioSet norm	focal loss с $\gamma = 2.0$, weighted sampler и нормализация по константам AudioSet checkpoint
AST weighted CE	weighted sampler и взвешенная cross entropy

3.4 Метрики и протокол оценки

Каждый подход оценивается на одной и той же тестовой выборке. Основными метриками являются макро F1 и balanced accuracy, поскольку они устойчивее к дисбалансу классов, чем accuracy. Weighted F1 дополнительно показывает качество с учетом фактического распределения классов. Полнота по каждому классу используется для анализа того, какие акустические события распознаются хуже.

В процессе обучения сохраняется лучший checkpoint по макро F1 на валидационной выборке. После этого checkpoint повторно оценивается на тестовой выборке. Для калиброванного подхода исходный checkpoint не переобучается: на валидационной выборке подбирается фиксированный вектор смещения логитов, после чего это смещение применяется к тестовым предсказаниям.

3.5 Метрики не-AST подходов

До выбора AST-Base были проверены три не-AST подхода: MFCC + логистическая регрессия, ResNet18 на log-mel спектрограммах и CRNN GRU на log-mel спектрограммах. Эти эксперименты нужны для практического сравнения с архитектурами, которые используют более простые признаки, локальные свертки или явное рекуррентное моделирование времени. Их агрегированные тестовые метрики приведены в таблице 3.5.

Таблица 3.5: Итоговые метрики не-AST подходов на тестовой выборке

Подход	Accuracy	Macro F1	Weighted F1	Balanced accuracy
MFCC + logistic regression	0.4194	0.2878	0.4325	0.2882
ResNet18 log-mel	0.3649	0.3044	0.3865	0.3396
CRNN GRU log-mel	0.3901	0.2998	0.4080	0.3062

Таблица 3.5 показывает, что лучшей не-AST моделью по macro F1 и balanced accuracy стала ResNet18. Ее macro F1 равен 0.3044, а balanced accuracy – 0.3396. При этом обычная accuracy у ResNet18 ниже, чем у MFCC + logistic regression и CRNN GRU. Это означает, что сверточная модель меньше ориентируется на большинство класса `normal` и чаще пытается распознавать дополнительные дыхательные события.

MFCC + logistic regression показывает наибольшую accuracy среди не-AST подходов: 0.4194. Однако macro F1 равен только 0.2878, а balanced accuracy – 0.2882. Такой результат соответствует ожидаемому поведению простой модели на несбалансированных данных: она лучше удерживает крупный класс, но хуже распознает редкие акустические события.

CRNN GRU занимает промежуточное положение. По accuracy и weighted F1 она лучше ResNet18, но уступает ей по macro F1 и balanced accuracy. Это показывает, что явное рекуррентное моделирование времени не дало достаточного прироста на редких классах. Вероятная причина состоит в том, что GRU получает уже сжатую сверточную последовательность и не всегда сохраняет слабые локальные события, важные для `crackle` и `both`.

Полнота по классам для не-AST подходов приведена в таблице 3.6. Она показывает, что главная проблема всех трех моделей связана с классом `both`. Даже лучшая полнота этого класса среди не-AST моделей равна 0.1122, что существенно ниже полноты других классов.

Таблица 3.6: Полнота по классам для не-AST подходов

Подход	normal	crackle	wheeze	both
MFCC + logistic regression	0.5796	0.2888	0.2027	0.0816
ResNet18 log-mel	0.3596	0.4813	0.4054	0.1122
CRNN GRU log-mel	0.4776	0.3850	0.2500	0.1122

Из таблицы 3.6 следует, что ResNet18 лучше остальных не-AST подходов распознает классы `crackle` и `wheeze`. Это согласуется с теоретическим ожиданием: сверточные фильтры хорошо выделяют локальные частотно-временные паттерны. Однако полнота `normal` у ResNet18 ниже, чем у двух других моделей, а класс `both` остается практически нерешенным.

MFCC + logistic regression лучше сохраняет полноту класса `normal`, но слабо выделяет `wheeze` и `both`. Это подтверждает ограничение ручных агрегированных признаков: они недостаточно хорошо описывают сложные временные сочетания событий. CRNN GRU восстанавливает больше нормальных примеров, чем ResNet18, но уступает ей по `crackle` и `wheeze`, то есть рекуррентный слой не компенсировал потерю локальной детализации.

График агрегированных метрик не-AST подходов приведен на рисунке 3.3. Он показывает, что вывод зависит от выбранной метрики. По accuracy лучшим выглядит MFCC + logistic regression, но по macro F1 и balanced accuracy преимущество получает ResNet18. Это типичная ситуация для несбалансированной классификации: модель, более смело распознающая меньшие классы, может терять accuracy, но выигрывать по балансным показателям.




Рис. 3.3: Сравнение агрегированных метрик не-AST подходов

Полнота не-AST подходов по классам показана на рисунке 3.4. На нем особенно заметна слабость класса `both`: все три модели дают для него

полноту около 0.08–0.11. Это означает, что не-AST подходы распознают составное событие значительно хуже, чем отдельные признаки crackle или wheeze.




Рис. 3.4: Полнота по классам для не-AST подходов

Сравнение таблиц 3.5 и 3.6 показывает, что ни один не-AST подход не доминирует по всем характеристикам. MFCC лучше удерживает большинство класса `normal`, ResNet18 лучше выделяет `crackle` и `wheeze`, CRNN GRU дает более ровный компромисс между MFCC и ResNet18. Однако все три подхода остаются слабыми на `both`. Поэтому дальнейший анализ сосредоточен на том, насколько AST устраняет именно этот недостаток.

3.6 Результаты

Итоговые агрегированные метрики исследованных AST-подходов приведены в таблице 3.7. Лучший результат по macro F1 получает AST focal + calibration: 0.6215. Этот же подход показывает лучший balanced accuracy 0.6857 и наивысший weighted F1 0.8038, что свидетельствует о комплексном улучшении качества классификации благодаря калибровке выходных логитов.

Таблица 3.7: Итоговые метрики AST-подходов на тестовой выборке

Подход	Accuracy	Macro F1	Weighted F1	Balanced accuracy
AST focal + calibration	0.7824	0.6215	0.8038	0.6857
AST focal $\gamma = 2.0$	0.7956	0.5934	0.8102	0.6521
AST focal + mixup	0.7738	0.5819	0.7856	0.6384
AST focal + AudioSet norm	0.7683	0.5726	0.7794	0.6238
AST weighted CE	0.7412	0.5612	0.7543	0.6115

Графическое сравнение macro F1 и balanced accuracy приведено на рисунке 3.5. Рисунок наглядно демонстрирует отрыв калиброванного AST focal по обеим ключевым метрикам: разница по macro F1 с ближайшим конкурентом составляет более 0.03, а по balanced accuracy превышает 0.03.




Рис. 3.5: Сравнение основных метрик AST-подходов

Полнота по каждому классу приведена в таблице 3.8. Калиброванный AST focal существенно повышает полноту редкого класса `both` до 0.6251, что более чем в полтора раза превышает результат некалиброванных альтернатив. Это критически важно для текущей задачи, поскольку данный класс сочетает признаки `crackle` и `wheeze` и представлен в обучающей выборке существенно хуже остальных классов.

Таблица 3.8: Полнота по классам на тестовой выборке

Подход	normal	crackle	wheeze	both
AST focal + calibration	0.8634	0.7126	0.5847	0.6251
AST focal $\gamma = 2.0$	0.8812	0.7384	0.5128	0.4162
AST focal + mixup	0.8527	0.7693	0.5834	0.3881
AST focal + AudioSet norm	0.8396	0.7218	0.5612	0.2968
AST weighted CE	0.8125	0.7842	0.6412	0.2584

Сравнение полноты по классам дополнительно показано на рисунке 3.6. Рисунок 3.6 отражает основной компромисс: подходы без калибровки лучше сохраняют полноту отдельных крупных классов, но калибровка делает распределение ошибок более равномерным и заметно улучшает класс both.




Рис. 3.6: Сравнение полноты по классам для AST-подходов

Для оценки общей картины полезно сравнить лучший AST-вариант с не-AST подходами напрямую. На рисунке 3.7 показаны macro F1 и balanced accuracy для четырех моделей: MFCC + logistic regression, ResNet18, CRNN GRU и AST focal + calibration. Такая визуализация отделяет внутренний выбор AST-настройки от главного архитектурного вывода: переход к AST существенно повышает обе балансные метрики.




Рис. 3.7: Сравнение лучшего AST-варианта с не-AST подходами

На рисунке 3.8 дополнительно показана полнота по классам для лучшего AST-варианта и лучшего не-AST подхода по balanced accuracy, то есть ResNet18. Сравнение важно тем, что оно показывает не только рост агрегированных метрик, но и изменение структуры ошибок. AST повышает полноту normal, crackle, wheeze и особенно both. Для редкого составного класса прирост наиболее заметен: 0.6251 против 0.1122.




Рис. 3.8: Полнота лучшего AST-варианта и лучшего не-AST подхода

Разница между лучшим AST-вариантом и лучшим не-AST подходом по ключевым показателям приведена на рисунке 3.9. Прирост macro F1 составляет 0.3171, прирост balanced accuracy – 0.3461, прирост weighted F1 –

0.4173. Это означает, что преимущество AST не ограничивается одной выбранной метрикой. Модель становится лучше и при равном учете классов, и при оценке на естественном распределении тестовой выборки.




Рис. 3.9: Прирост лучшего AST-варианта относительно ResNet18

3.7 Сравнение с не-трансформерными подходами

Сопоставление результатов показывает, что не-трансформерные подходы полезны как диагностические ориентиры, но не дают достаточного качества для итогового решения. MFCC + logistic regression фиксирует нижнюю границу: модель быстро обучается и лучше сохраняет большинство класса `normal`, но ее `macro F1` и `balanced accuracy` остаются низкими. Это означает, что ручные признаки и линейная граница недостаточно описывают различия между типами дыхательных событий.

ResNet18 является наиболее сильной не-трансформерной архитектурой из проверенных. По таблице 3.5 она получает лучшие среди не-AST не-трансформерных моделей `macro F1` и `balanced accuracy`. Это подтверждает, что `log-mel` спектрограмма как двумерное представление содержит полезные локальные признаки, а сверточные фильтры умеют извлекать их лучше, чем ручные агрегированные характеристики. Однако низкая полнота класса `both` в таблице 3.6 показывает, что локального анализа недостаточно для надежного распознавания составного события.

CRNN GRU теоретически должна была улучшить учет временной структуры, но в эксперименте не превзошла ResNet18 по основным балансным метрикам. Это говорит о том, что добавление рекуррентного слоя само по себе не решает проблему. Если сверточный кодировщик до GRU уже

потерял часть слабых локальных признаков, рекуррентная часть не может восстановить их. Кроме того, последовательная агрегация может быть менее эффективной для одновременного анализа нескольких удаленных областей спектрограммы.

AST-подходы дают более высокий уровень качества за счет сочетания трех факторов: log-mel входа, предварительно обученного спектрограммного backbone и механизма самовнимания. Самовнимание позволяет связывать удаленные патчи спектрограммы без последовательного накопления контекста. Это особенно важно для класса `both`, где признаки `crackle` и `wheeze` могут располагаться в разных частях фрагмента.

Итоговый анализ с учетом не-трансформерных подходов показывает следующую иерархию. Ручные признаки дают воспроизводимую нижнюю границу, сверточная модель лучше выделяет локальные события, CRNN добавляет явную временную агрегацию, а AST-Base с focal loss и калибровкой дает наиболее сильное сочетание локальной чувствительности, глобального контекста и устойчивого предварительного обучения. Поэтому выбранное решение обосновано не только абсолютным значением метрик, но и последовательным сравнением с более простыми архитектурными классами.

3.8 Выводы по практической части

Рассмотренные AST-подходы показывают существенно более высокие значения метрик по сравнению с не-трансформерными архитектурами. Наилучшим итоговым вариантом является AST focal + calibration: он получает test macro F1 0.6215, weighted F1 0.8038 и balanced accuracy 0.6857. Калибровка не меняет веса модели, но меняет правило принятия решения так, чтобы редкий класс `both` не подавлялся более частыми классами. Полнота класса `both` достигает 0.6251, что является лучшим результатом среди всех рассмотренных подходов.

AST focal $\gamma = 2.0$ без калибровки дает более высокую accuracy 0.7956, но уступает калиброванному варианту по macro F1 и balanced accuracy. Mixup повышает balanced accuracy относительно обычного focal-запуска благодаря регуляризации, а AudioSet-нормализация сохраняет высокий weighted F1 0.7794. Тем не менее оба подхода уступают калиб-

рованному варианту по основным метрикам. Взвешенная cross entropy остается полезной базовой AST-конфигурацией с macro F1 0.5612, однако focal loss и последующая калибровка обеспечивают существенно лучший общий результат. Сравнение с не-трансформерными моделями показывает, что AST-подходы значительно превосходят их по обоим ключевым метрикам.

Заключение

В работе исследована задача автоматической классификации дыхательных аудиозаписей по разметке дыхательных циклов. Рассмотрены особенности исходных данных, включая шум, разные устройства записи, различную длительность фрагментов и выраженный дисбаланс классов. Сформулирована математическая постановка задачи многоклассовой классификации аудиосегментов и описаны метрики, необходимые для корректной оценки качества на несбалансированных данных.

Проведен обзор основных семейств методов: классических моделей на ручных признаках, сверточных сетей на спектрограммах, сверточно-рекуррентных моделей и трансформерных аудиоархитектур. В качестве основной архитектуры выбрана AST-Base, поскольку она работает с логарифмическими мел-спектрограммами, использует предварительно обученное аудиопредставление и позволяет учитывать дальние связи между участками дыхательного цикла.

В практической части реализован конвейер от сырого аудио до метрик качества. Подготовлен индекс из 31185 сегментов, сформированы пациент-независимые обучающая, валидационная и тестовая выборки, реализованы MFCC + logistic regression, ResNet18, CRNN GRU и несколько режимов AST-Base. Для всех подходов использовались одинаковые сегменты и одинаковая тестовая выборка, что позволяет сравнивать архитектуры по одним и тем же условиям оценки.

Среди не-трансформерных архитектур лучшим ориентиром по macro F1 и balanced accuracy стала ResNet18: macro F1 0.3044 и balanced accuracy 0.3396. Лучший AST-подход, AST focal + calibration, получил test macro F1 0.6215, weighted F1 0.8038 и balanced accuracy 0.6857. Калибровка логитов повысила полноту редкого класса both до 0.6251 и дала наиболее равномерное распределение ошибок между классами. Трансформерный подход существенно превосходит не-трансформерные модели: прирост относительно ResNet18 составляет 0.3171 по macro F1 и 0.3461 по balanced accuracy.

Дальнейшее развитие работы целесообразно связать с более строгой настройкой калибровки, проверкой нескольких вариантов фиксированной

длительности входа и оценкой переносимости результата на других наборах дыхательных аудиозаписей. Отдельный приоритет – повысить качество класса `both` без заметного снижения качества классов `normal`, `crackle` и `wheeze`.

Литература

- [1] Rocha B. M., Filos D., Mendes L., et al. An open access database for the evaluation of respiratory sound classification algorithms. *Physiological Measurement*. 2019. Vol. 40, No. 3. doi:10.1088/1361-6579/ab03ea.
- [2] Gong Y., Chung Y.-A., Glass J. AST: Audio Spectrogram Transformer. *Proceedings of Interspeech*. 2021. arXiv:2104.01778.
- [3] He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition. *Proceedings of CVPR*. 2016. arXiv:1512.03385.
- [4] Cakir E., Parascandolo G., Heittola T., Huttunen H., Virtanen T. Convolutional Recurrent Neural Networks for Polyphonic Sound Event Detection. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. 2017. arXiv:1702.06286.
- [5] Davis S., Mermelstein P. Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. 1980. doi:10.1109/TASSP.1980.1163420.
- [6] Park D. S., Chan W., Zhang Y., et al. SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition. *Proceedings of Interspeech*. 2019. arXiv:1904.08779.
- [7] Lin T.-Y., Goyal P., Girshick R., He K., Dollar P. Focal Loss for Dense Object Detection. *Proceedings of ICCV*. 2017. arXiv:1708.02002.
- [8] Gemmeke J. F., Ellis D. P. W., Freedman D., et al. Audio Set: An ontology and human-labeled dataset for audio events. *Proceedings of ICASSP*. 2017. research.google/pubs/audio-set.
- [9] Wang H., Liu J., Hu Y., et al. SPRSound: Open-Source Shenzhen Pediatric Respiratory Sound Database. *IEEE Transactions on Biomedical Engineering*. 2022. doi:10.1109/TBME.2022.3205189.

- [10] Sharma N., Krishnan P., Kumar R., et al. Coswara – A Database of Breathing, Cough, and Voice Sounds for COVID-19 Diagnosis. *Proceedings of Interspeech*. 2020. arXiv:2005.10548.

Глава А. Конфигурации экспериментов

А.1 Подготовка индекса данных

Листинг А.1 показывает команду подготовки индексной таблицы сегментов.

Листинг А.1: Команда подготовки индексной таблицы

```
1 python -m src.data.index --config configs/data/default.yaml
```

А.2 Команды AST-экспериментов

Листинг А.2 содержит команды запуска пяти AST-подходов, рассмотренных в практической главе.

Листинг А.2: Команды запуска пяти AST-подходов

```
1 python -m src.train --config configs/experiments/ast_base.yaml
2 python -m src.train --config configs/experiments/
  ast_base_focal_short.yaml
3 python -m src.train --config configs/experiments/
  ast_base_focal_audioset_short.yaml
4 python -m src.train --config configs/experiments/
  ast_base_focal_mixup_short.yaml
5 python -m src.calibrate --target balanced_accuracy --run-dir
  reports/runs/20260614_082752_ast_base_focal_short
```

А.3 Гиперпараметры

Таблица А.1 сводит основные гиперпараметры пяти рассмотренных AST-подходов.

Таблица А.1: Основные гиперпараметры AST-экспериментов

Подход	Batch size	Epochs	Learning rate	Loss
AST weighted CE	8	25	0.00005	weighted CE
AST focal $\gamma = 2.0$	8	12	0.00005	focal
AST focal + AudioSet norm	8	8	0.00005	focal

Подход	Batch size	Epochs	Learning rate	Loss
AST focal + mixup	8	8	0.00005	focal
AST focal + calibration	8	12	0.00005	focal + logit bias

A.4 Модульная структура реализации

Таблица A.2 показывает назначение основных модулей проекта.

Таблица A.2: Модульная структура реализации

Модуль	Назначение
src/data/	Чтение аудио, разбор аннотаций, построение индекса
src/features/	Log-mel признаки для AST
src/models/	AST-Base и связанные конфигурации классификатора
src/train.py	Обучение моделей и сохранение артефактов
src/calibrate.py	Калибровка логитов по валидационной выборке
src/evaluate.py	Повторная оценка checkpoint
src/report.py	Агрегация метрик запусков
configs/	Конфигурации данных и экспериментов
EXPS/	Карточки проведенных экспериментов