

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего
образования
«Московский государственный технический университет имени Н. Э. Баумана»

Итоговый отчет по дипломной работе

Прогнозирование респираторной болезни на основе анализа звукозаписи дыхания

Выполнил: студент

Руководитель: _____

Москва, 2026

Оглавление

Введение	3
1 Обзор области и постановка задачи	5
1.1 Прикладной и технический контекст	5
1.2 Обзор существующих решений	6
1.3 Обзор датасетов	17
1.4 Постановка задачи	21
1.5 Математическая постановка	21
1.6 Метрики качества	22
2 Теоретическое описание выбранного решения	26
2.1 Общий конвейер AST-Base	26
2.2 Требования к входному аудиофрагменту	26
2.3 Преобразование аудиосигнала	28
2.4 Акустические признаки целевых классов	30
2.5 Патчи спектрограммы и вход трансформера	31
2.6 Блок самовнимания	33
2.7 Адаптация предварительно обученной AST-Base	36
2.8 Классификационная голова и перенос обучения	37
2.9 Функция потерь и учет дисбаланса	38
2.10 Регуляризация и аугментации спектрограмм	39
2.11 Организация обучения и валидации	40
2.12 Параметры обучения и ограничения	41
3 Практическая реализация и анализ результатов	43
3.1 Среда и инструменты	43
3.2 Подготовка данных	43
3.3 Экспериментальные конфигурации	45
3.4 Метрики и протокол оценки	46
3.5 Динамика обучения нейросетевых моделей	47
3.5.1 ResNet18	49
3.5.2 CRNN GRU	49

3.6	Результаты	50
3.7	Анализ ошибок	56
3.8	Работа с несбалансированной выборкой	57
3.9	Выводы по практической части	59
Заключение		60
Список литературы		62
A	Конфигурации и команды запуска	64
A.1	Подготовка индекса данных	64
A.2	Команды обучения	64
A.3	Гиперпараметры моделей	64
A.4	Модульная структура реализации	65

Введение

Дыхательные аудиозаписи являются удобным объектом для задач автоматической классификации аудиосигналов. Такой тип данных может быть получен без сложного измерительного оборудования, допускает повторные измерения и может использоваться для последующего анализа большого числа коротких фрагментов. При этом ручной анализ аудиозаписей плохо масштабируется, зависит от качества записи, условий получения сигнала и единообразия разметки.

В работе рассматривается задача классификации коротких фрагментов дыхательных аудиозаписей по датасетной разметке. В качестве целевых классов используются состояния дыхательного цикла: `normal`, `crackle`, `wheeze` и `both`. Результат работы модели интерпретируется как классификация аудиофрагмента, а не как самостоятельное медицинское заключение. Такое ограничение важно, поскольку используемые данные содержат акустические события и не задают полноценную клиническую постановку диагноза.

Сырой набор данных требует отдельного конвейера предварительной обработки. Записи отличаются длительностью, частотой дискретизации, уровнем шума и устройствами записи. Размеченные дыхательные циклы имеют разную продолжительность, а распределение классов является несбалансированным. Поэтому качество модели нельзя оценивать только по обычной доле правильных ответов: необходимо использовать метрики, учитывающие редкие классы и ошибки по каждому классу.

Методы машинного обучения позволяют автоматически выделять признаки, связанные с характерными акустическими событиями, такими как хрипы `crackle`, свистящие компоненты `wheeze` и их совместное появление. В работе сравниваются несколько семейств моделей: классические модели на ручных признаках, сверточные сети на логарифмических мел-спектрограммах, сверточно-рекуррентная модель и трансформерная архитектура `Audio Spectrogram Transformer`.

Цель работы состоит в исследовании качества современных методов анализа дыхательных аудиозаписей и выборе базовой архитектуры размером менее 100 млн параметров для последующего предметно-

ориентированного обучения.

Объектом исследования являются аудиозаписи дыхания. Предметом исследования являются методы классификации дыхательных аудиосигналов на основе ручных признаков, спектрограмм и предварительно обученных нейросетевых представлений.

Для достижения цели решаются следующие задачи:

1. разработать воспроизводимый конвейер подготовки аудиосегментов из сырого набора данных;
2. сформировать пациент-независимые обучающую, валидационную и тестовую выборки;
3. реализовать базовую модель на ручных признаках;
4. реализовать модели ResNet, CRNN и AST-Base для классификации логарифмических мел-спектрограмм;
5. сравнить модели по accuracy, balanced accuracy, macro F1, weighted F1 и полноте по каждому классу;
6. проанализировать ограничения полученного решения и направления дальнейшего развития.

Практическим результатом работы является программная реализация конвейера обработки данных, обучение нескольких моделей и оценка качества классификации на тестовой выборке. Итоговая архитектура AST-Base содержит 86м параметров, укладывается в заданное ограничение и показывает наилучшие значения агрегированных метрик среди проведенных экспериментов.

Глава 1. Обзор области и постановка задачи

1.1 Прикладной и технический контекст

Дыхательные звуки представляют собой нестационарные аудиосигналы, в которых полезные события могут занимать небольшую часть записи. В зависимости от состояния дыхательного цикла в сигнале могут присутствовать короткие дискретные компоненты, длительные тональные компоненты, фоновый шум, паузы и участки с низкой амплитудой. Для автоматической обработки такие записи сначала приводятся к единому формату, затем разбиваются на сегменты и преобразуются в признаки.

Актуальность автоматической классификации дыхательных аудиосегментов определяется несколькими факторами. Во-первых, аудиозаписи можно получать относительно просто и многократно. Во-вторых, один и тот же тип данных подходит для массового сбора, последующего анализа и сравнения разных алгоритмов. В-третьих, ручная обработка больших наборов записей требует значительного времени и зависит от качества разметки. Автоматическая модель может использоваться как вспомогательный инструмент предварительной сортировки и анализа аудиосегментов.

В прикладной постановке на вход модели подается короткий фрагмент дыхательной аудиозаписи. На выходе требуется получить один из классов звукового события или состояния сегмента. В настоящей работе используются четыре класса: нормальный дыхательный цикл, цикл с хрипом *crackle*, цикл со свистящим компонентом *wheeze* и цикл с одновременным присутствием обоих событий. Такая постановка совпадает с форматом разметки ICBNI-style, где для каждого дыхательного цикла заданы время начала, время окончания и бинарные признаки наличия *crackle* и *wheeze*.

Техническая сложность задачи связана с несколькими свойствами данных. Информативные события могут быть короткими и слабо выраженными. Классы могут быть похожи между собой по спектральным и временным признакам. Записи отличаются громкостью, длительностью, частотой дискретизации и уровнем фонового шума. Кроме того, распределение классов является несбалансированным: редкий класс *both* встреча-

ется значительно реже, чем класс `normal`. Поэтому простая ассигасу не отражает реальное качество классификации.

Задача подходит для исследования современных методов представления аудио и переноса обучения. С одной стороны, можно построить простую нижнюю границу качества на ручных признаках, таких как MFCC и спектральные статистики. С другой стороны, логарифмические мел-спектрограммы позволяют использовать сверточные и трансформерные модели, а предварительно обученные аудиоэнкодеры позволяют компенсировать ограниченный размер размеченного набора данных.

1.2 Обзор существующих решений

Методы классификации дыхательных аудиозаписей можно разделить на четыре основные группы. Такое деление удобно не только исторически, но и технически: каждая группа по-своему решает вопрос представления аудиосигнала, учета временной структуры и борьбы с ограниченным размером размеченных данных. В ранних подходах основное внимание уделялось ручному построению признаков, затем доминирующими стали сверточные модели на спектрограммах, после чего появились гибридные сверточно-рекуррентные схемы и трансформерные архитектуры с переносом обучения.

Первая группа включает ручные признаки и классические алгоритмы машинного обучения. В этом подходе из сигнала извлекаются MFCC [5], спектральный центроид, ширина спектра, roll-off, RMS, zero crossing rate и их статистики по времени. После этого обучается классификатор, например логистическая регрессия, метод опорных векторов или случайный лес. Такой подход прост, быстро воспроизводится и хорошо подходит для нижней границы качества, но его возможности ограничены ручным выбором признаков.

Основная идея ручных признаков состоит в том, что аудиосигнал заранее переводится в компактный вектор, который должен сохранить наиболее важные свойства исходной записи. Например, MFCC описывают огибающую спектра и хорошо подходят для многих задач обработки речи и акустических событий. Для дыхательных записей такие признаки также полезны, поскольку позволяют зафиксировать общую форму спектра,

изменение энергии по частотам и некоторые различия между нормальным дыханием и дополнительными звуковыми событиями. Однако MFCC и сходные признаки не всегда достаточно хорошо описывают короткие локальные события. Хрип *crackle* может занимать малую часть дыхательного цикла, поэтому его вклад может быть сглажен при усреднении признаков по всему фрагменту.

Классические модели поверх ручных признаков обычно используют небольшое число параметров и быстро обучаются. Это важно при первом анализе набора данных: можно проверить корректность разметки, разбиения, извлечения сегментов и метрик без длительного обучения нейронной сети. Кроме того, такие модели проще интерпретировать. Если классификатор использует логистическую регрессию, можно анализировать веса признаков и понимать, какие статистики сильнее влияют на решение. Если используется метод опорных векторов, можно оценить, насколько классы разделимы в выбранном признаковом пространстве. Если используется случайный лес, можно получить приближенную важность признаков.

Недостаток ручных признаков состоит в их ограниченной выразительности. Проектировщик заранее решает, какие характеристики сигнала будут измеряться. Если выбранные признаки не отражают различия между *crackle*, *wheeze* и *both*, классификатор не сможет восстановить потерянную информацию. Дополнительная трудность связана с тем, что дыхательные записи часто имеют разную длительность. Чтобы получить фиксированный вектор, временную ось обычно агрегируют средним, стандартным отклонением, минимумом и максимумом. Такая агрегация удобна, но она ослабляет сведения о порядке событий внутри дыхательного цикла.

Ручные признаки также чувствительны к устройствам записи. Разные микрофоны и стетоскопы могут по-разному усиливать частоты, поэтому статистики спектра частично отражают не только дыхательное событие, но и свойства устройства. Для небольшой выборки это особенно опасно: классификатор может научиться отличать источник записи или пациента вместо целевого класса. Поэтому ручные признаки остаются полезной базовой линией, но не являются достаточным решением для основной модели.

Вторая группа включает сверточные нейронные сети на спектрограммах. После преобразования аудиосигнала в логарифмическую мел-спектрограмму задача становится близкой к классификации двумерных частотно-временных представлений. Архитектуры ResNet [3] и сходные сверточные модели хорошо выделяют локальные шаблоны, что полезно для событий *crackle* и *wheeze*. Недостатком является ограниченность локальных сверток при моделировании длинных зависимостей внутри дыхательного цикла.

Сверточные сети используют другое предположение о данных. Вместо того чтобы заранее усреднять признаки по времени, спектрограмма рассматривается как двумерное изображение, где одна ось соответствует времени, а другая – частоте. Локальные свертки выделяют повторяющиеся фрагменты: короткие всплески энергии, полосы устойчивой частоты, переходы между участками дыхательного цикла. Это хорошо согласуется с природой дыхательных событий. *Crackle* часто проявляется как короткая локальная структура, а *wheeze* может выглядеть как более протяженный тональный компонент.

Архитектуры семейства ResNet получили широкое распространение благодаря остаточным соединениям. Остаточные соединения позволяют обучать более глубокие сети и уменьшают риск исчезающих градиентов. В задачах анализа спектрограмм это полезно, потому что ранние слои могут выделять простые локальные элементы, а более поздние слои – составные паттерны, связанные с целевыми классами. При адаптации ResNet к аудио обычно изменяется первый сверточный слой, поскольку вход имеет один канал, а не три цветовых канала изображения. Последний полносвязный слой заменяется на классификатор с нужным числом классов.

Главное преимущество CNN-подхода состоит в автоматическом извлечении признаков. Модель сама учится находить локальные структуры, важные для классификации, и не ограничивается заранее выбранным набором спектральных статистик. Кроме того, сверточные модели хорошо параллелятся на GPU и обычно быстрее трансформеров при одинаковой длине входа. Поэтому CNN часто используются как сильная базовая линия для аудиоклассификации.

Однако у сверточных моделей есть ограничения. Свертка имеет ло-

кальное поле зрения, а глобальные зависимости формируются только после нескольких слоев и операций пулинга. В дыхательном цикле это может быть недостаточно: класс сегмента может зависеть не только от отдельного локального события, но и от распределения событий по всей длительности фрагмента. Кроме того, если применяется сильное уменьшение размерности, мелкие события могут исчезать. Это особенно важно для редких и коротких фрагментов `crackle`.

Еще одна проблема связана с обучением на малых и шумных данных. Сверточная сеть может переобучаться на особенности конкретных пациентов или записывающих устройств. Визуально похожие спектрограммы могут относиться к разным классам из-за тонких акустических различий, а спектрограммы одного класса могут сильно различаться из-за шума и длительности. Поэтому CNN требует аккуратной балансировки классов, выбора длительности входа, регуляризации и проверки на пациент-независимом разбиении.

Третья группа включает сверточно-рекуррентные модели. В них сверточный кодировщик извлекает локальные признаки спектрограммы, а рекуррентный слой LSTM или GRU моделирует временную структуру [4]. Такой подход естественен для аудиосигналов, но требует дополнительной настройки и не всегда превосходит более простые сверточные модели на малых наборах данных.

CRNN-подход возник из необходимости одновременно учитывать локальные частотно-временные признаки и порядок событий во времени. В типичной схеме сверточная часть обрабатывает спектрограмму и формирует последовательность признаков. Затем эта последовательность подается в LSTM или GRU, которые обновляют скрытое состояние вдоль временной оси. После этого скрытые состояния агрегируются и используются для классификации. Такая архитектура ближе к естественной структуре аудиосигнала, чем чистая CNN, поскольку дыхательный цикл является последовательностью, а не просто набором независимых локальных фрагментов.

Для дыхательных записей это особенно важно в задачах, где необходимо учитывать фазы вдоха и выдоха, длительность события и его положение внутри цикла. Например, свистящий компонент может быть более

выражен на определенной части дыхания. Рекуррентная часть потенциально может учитывать такие зависимости. GRU при этом часто выбирается как более компактная альтернатива LSTM: она имеет меньше параметров и проще обучается на небольших данных.

Преимущество CRNN состоит в том, что модель сохраняет некоторую интерпретируемость обработки: сверточный блок отвечает за локальное описание спектрограммы, а рекуррентный блок – за последовательную динамику. Кроме того, CRNN может быть компактнее глубокой CNN или трансформера, что важно для ограниченных вычислительных ресурсов. В практических задачах это делает CRNN хорошим промежуточным вариантом между простой сверточной моделью и более крупной трансформерной архитектурой.

Недостатки CRNN связаны с обучением и масштабированием. Рекуррентные слои сложнее параллелить по времени, чем свертки или attention. При длинной последовательности обучение может быть медленнее. Кроме того, качество CRNN зависит от того, насколько удачно сверточный кодировщик подготовил последовательность для рекуррентного блока. Если важные локальные события потеряны на этапе свертки и пулинга, GRU или LSTM не смогут восстановить эту информацию.

На малых наборах данных CRNN также может переобучаться. Рекуррентный блок добавляет параметры и делает модель чувствительной к порядку кадров, но это не гарантирует улучшения качества. Если разметка шумная, а классы пересекаются по признакам, модель может запоминать частные временные паттерны. Поэтому CRNN полезна как базовая линия, но ее преимущество над CNN нужно подтверждать экспериментально, а не принимать заранее.

Четвертая группа включает трансформерные модели для аудио. Audio Spectrogram Transformer разбивает спектрограмму на патчи и обрабатывает их механизмом самовнимания [2]. Преимущество такого подхода состоит в возможности учитывать глобальные зависимости между участками спектрограммы. При ограничении размера модели менее 100 млн параметров основным кандидатом является AST-Base, поскольку он сочетает предварительно обученное аудиопредставление, работу со спектрограммами и приемлемое число параметров.

Трансформерный подход отличается от CNN и CRNN тем, что модель напрямую строит связи между всеми токенами входной последовательности. В случае AST токенами являются патчи спектрограммы. Каждый патч описывает локальный участок во времени и частоте, а механизм самовнимания позволяет одному участку учитывать остальные. Это важно для дыхательных аудиосегментов, потому что целевой класс может зависеть от нескольких разнесенных во времени признаков. Например, сегмент класса `both` может содержать короткие хрипы и протяженный свистящий компонент, расположенные в разных областях спектрограммы.

Самовнимание позволяет модели не ограничиваться фиксированным локальным окном. В сверточной сети дальние зависимости формируются через последовательность слоев, а в трансформере каждый токен может сразу получить информацию от других токенов через матрицу внимания. Это делает AST привлекательным для аудиозадач, где важны как локальные, так и глобальные признаки. При этом спектрограмма остается удобным входным представлением: она сохраняет частотно-временную структуру и совместима с `patch embedding`.

Ключевым фактором успешного применения AST является предварительное обучение. Полное обучение трансформера с нуля требует большого количества данных. В дыхательных датасетах обычно доступно ограниченное число размеченных циклов, поэтому обучение с нуля может привести к переобучению. Предварительно обученная AST-модель уже содержит представления общих аудиособытий, а дообучение адаптирует их к дыхательным классам. Такой перенос обучения особенно важен для редких классов, где число примеров недостаточно для формирования устойчивых признаков с нуля.

В то же время трансформеры не являются автоматическим решением всех проблем. Они чувствительны к длине входа, параметрам спектрограммы и стратегии обучения. Если вход слишком длинный, возрастает вычислительная стоимость. Если вход слишком короткий, часть дыхательного события может быть потеряна. Если модель дообучается слишком агрессивно, она может быстро переобучиться на обучающую выборку. Поэтому для AST-Base важны выбор `learning rate`, взвешенная функция потерь, взвешенная выборка и контроль качества по `validation macro F1`.

Для данной работы AST-Base является разумным компромиссом между качеством и размером. Модель меньше ограничения 100 млн параметров, но достаточно выразительна для обработки спектрограмм. Она позволяет использовать предварительное обучение, глобальное внимание и классификационную голову на четыре класса. Поэтому AST-Base выбрана как основное решение, а остальные модели используются как базовые линии для проверки того, насколько трансформерный подход улучшает качество.

Сравнение четырех групп методов показывает, что они решают разные части задачи. Ручные признаки дают быстрый и интерпретируемый baseline. CNN выделяет локальные частотно-временные паттерны. CRNN добавляет явное моделирование временной последовательности. AST-Base объединяет спектрограммное представление с глобальным attention и переносом обучения. Поэтому экспериментальная часть должна включать все эти группы, но теоретическое описание основного решения целесообразно сосредоточить на AST-Base.

Отдельно следует отметить роль дисбаланса классов в выборе метода. Если модель оптимизируется только на общую accuracy, она может отдавать предпочтение классу `normal`. Это особенно вероятно для ручных признаков и простых классификаторов. Более сложные модели также подвержены этому риску, если не использовать `class weighting` или `weighted sampler`. Поэтому современные решения для дыхательных записей обычно оцениваются не только по accuracy, но и по `macro F1`, `balanced accuracy` и `recall` редких классов. Эти метрики позволяют видеть, улучшает ли модель распознавание `crackle`, `wheeze` и `both`, а не только большинство.

Таким образом, существующие решения можно рассматривать как последовательное усложнение способа представления аудиосигнала. Ручные признаки используют заранее заданные статистики. CNN учится локальным структурам спектрограммы. CRNN учитывает временную динамику после сверточного кодирования. AST-Base обрабатывает всю спектрограмму как последовательность патчей и использует глобальные связи между ними. Именно последний подход лучше соответствует цели работы: выбрать современную, но не чрезмерно крупную архитектуру для предметно-ориентированного обучения дыхательных аудиосегментов.

При анализе существующих решений отдельно рассматривается этап предварительной обработки, поскольку во многих работах именно он существенно влияет на итоговое качество. Даже если архитектура модели остается неизменной, изменение частоты дискретизации, длительности сегмента, числа мел-каналов или способа нормализации может заметно изменить результат. Для дыхательных записей это особенно важно: полезные события часто кратковременны, а записи могут содержать тишину, шум трения, фоновые разговоры или неодинаковое усиление разных частот.

Один из ключевых вопросов предварительной обработки – выбор длительности входного фрагмента. Если модель получает целую длинную запись, она должна сама находить информативные участки. Это усложняет задачу и требует больше данных. Если модель получает только размеченный дыхательный цикл, задача становится более контролируемой, но возникает необходимость приводить циклы к общей длине. Короткие циклы можно дополнять нулями, повторять циклически или растягивать во времени. Длинные циклы можно обрезать с начала, с конца или случайным образом. Каждый вариант имеет последствия. Нулевое дополнение может добавлять много тишины, циклическое дополнение может повторять одно и то же событие, а случайная обрезка может удалить важный участок.

Другой важный вопрос – частота дискретизации. Дыхательные записи в открытых наборах могут иметь разные исходные частоты, поэтому перед обучением их обычно приводят к единому значению. Слишком низкая частота может удалить высокочастотные компоненты, связанные с частью событий. Слишком высокая частота увеличивает размер входа и вычислительные затраты, но не всегда дает пропорциональный прирост качества. В данной работе используется 16 кГц как практический компромисс: такое значение достаточно для представления широкого диапазона дыхательных звуков и одновременно удобно для нейросетевого обучения.

Представление спектрограммы также выбирается не произвольно. Обычная STFT-спектрограмма сохраняет линейную частотную шкалу, тогда как mel-шкала уплотняет высокие частоты и больше соответствует восприятию звука. Логарифмирование энергии уменьшает динамический диапазон и делает слабые компоненты заметнее относительно сильных. По-

этому log-mel spectrogram стала стандартным представлением во многих задачах аудиоклассификации. Для дыхательных звуков она удобна тем, что одновременно сохраняет временную локализацию событий и компактно описывает частотную структуру.

В существующих решениях часто применяются аугментации. Их цель – увеличить разнообразие обучающей выборки и снизить переобучение. Для аудио могут использоваться добавление шума, изменение громкости, временной сдвиг, растяжение по времени, изменение высоты тона, маскирование частотных полос и временных интервалов. SpecAugment [6], например, маскирует участки спектрограммы и заставляет модель не полагаться на один узкий фрагмент входа. Для дыхательных данных аугментации нужно применять осторожно: слишком сильное изменение сигнала может исказить признаки `crackle` или `wheeze`.

Аугментации особенно полезны при дисбалансе классов. Если редкий класс представлен малым числом примеров, модель видит меньше вариантов его акустического проявления. Увеличение разнообразия редких классов может повысить recall. Однако простое копирование или чрезмерное повторение редких примеров может привести к переобучению. Поэтому аугментации должны сочетаться с взвешенной функцией потерь, взвешенной выборкой и проверкой качества на пациент-независимой валидации.

Перенос обучения является еще одним важным направлением существующих решений. В задачах общего аудио крупные модели могут обучаться на больших корпусах, где представлены тысячи типов звуковых событий. После такого предварительного обучения модель содержит признаки, полезные для анализа спектральных паттернов, временных структур и акустических переходов. В дыхательной задаче эти признаки не совпадают полностью с целевым доменом, но они могут служить хорошей начальной точкой. Поэтому дообучение предварительно обученной модели обычно предпочтительнее обучения трансформера с нуля.

Можно выделить несколько стратегий переноса обучения. Первая стратегия – feature extraction: базовая модель фиксируется, а поверх ее выходов обучается небольшой классификатор. Такой подход дешевле и снижает риск переобучения, но ограничивает адаптацию признаков к

дыхательному домену. Вторая стратегия – full fine-tuning: обновляются все параметры модели. Она более гибкая, но требует аккуратного выбора learning rate и регуляризации. Третья стратегия – parameter-efficient tuning, где обучаются только небольшие добавленные модули или часть параметров. Такая схема полезна, когда модель велика или данных мало. В данной работе выбран full fine-tuning AST-Base, поскольку модель укладывается в лимит 100 млн параметров и доступна GPU-среда.

Существующие решения также различаются по уровню, на котором выполняется классификация. В одних работах классифицируется целый аудиофайл, в других – отдельный дыхательный цикл, в третьих – короткое скользящее окно. Классификация целого файла может быть удобна, если разметка доступна только на уровне записи, но она затрудняет анализ конкретных событий. Классификация дыхательного цикла лучше соответствует разметке ICBN1 и позволяет сравнивать сегменты одинаковой природы. Скользящее окно подходит для обнаружения событий, но требует другого протокола оценки. В настоящей работе выбран уровень дыхательного цикла, поскольку он связан с имеющейся разметкой и позволяет использовать стандартную четырехклассовую постановку.

Отдельный класс решений связан с ансамблями. Ансамбль может объединять несколько моделей, обученных на разных признаках, разных разбиениях или разных архитектурах. Обычно ансамбли повышают качество, потому что ошибки отдельных моделей частично компенсируются. Например, одна модель может лучше распознавать crackle, другая – wheeze, а итоговое голосование или усреднение вероятностей дает более устойчивый ответ. Однако ансамбли сложнее воспроизводить, они требуют больше вычислений и хуже подходят для анализа одной базовой архитектуры. Поэтому в дипломной работе ансамблевый подход рассматривается как возможное развитие, но не выбирается в качестве основного решения.

Еще одно направление – облегченные модели для внедрения на ограниченных устройствах. В таких работах используются компактные CNN, pruning, distillation или quantization. Их цель – сохранить приемлемое качество при меньшем числе параметров и более быстрой инференс-процедуре. Для дыхательных записей это потенциально важно, если

модель должна работать на мобильном устройстве или встроенной системе. Однако задача настоящей работы состоит не в минимизации модели, а в выборе сильной базовой архитектуры до 100 млн параметров. Поэтому облегчение модели рассматривается как следующий этап после получения устойчивого качества.

Сравнение решений должно учитывать не только архитектуру, но и протокол оценки. Нельзя напрямую сопоставлять результаты, если использовались разные разбиения, разные уровни сегментации, разные классы или разные метрики. Например, бинарная задача `normal` против `non-normal` проще, чем четырехклассовая классификация. Случайное разбиение сегментов обычно дает более оптимистичную оценку, чем пациент-независимое разбиение. Поэтому в данной работе все модели сравниваются внутри одного протокола: одинаковый индекс сегментов, одинаковые `train/validation/test split` и одинаковые метрики.

Особое внимание уделяется классу `both`. С точки зрения модели это не просто еще один класс, а комбинация двух типов акустических событий. Если в сегменте признаки `crackle` выражены сильнее, модель может выбрать класс `crackle`. Если сильнее выражен тональный компонент, модель может выбрать `whoosh`. Для правильного распознавания `both` нужно, чтобы модель одновременно обнаружила оба признака и научилась считать их совместное присутствие отдельным классом. Это объясняет, почему класс `both` обычно труднее для всех семейств методов.

Ручные признаки в такой ситуации ограничены тем, что агрегация по времени может сгладить совместное присутствие событий. CNN лучше видит локальные структуры, но может сосредоточиться на наиболее ярком событии. CRNN может учитывать последовательность, но ее качество зависит от сверточного кодировщика. AST-Base имеет преимущество за счет `self-attention`: разные участки спектрограммы могут обмениваться информацией, поэтому модель потенциально лучше связывает короткие и длительные события внутри одного сегмента. Именно эта способность важна для обоснования выбора AST-Base.

В практическом смысле выбор архитектуры должен учитывать три требования. Первое требование – качество по редким классам, а не только по `majority class`. Второе требование – воспроизводимость: модель долж-

на запускаться в заданной среде, сохранять артефакты и оцениваться по единому протоколу. Третье требование – ограничение размера. Крупные foundation-модели могут быть сильными, но они сложнее для дипломной реализации и могут выходить за установленный лимит. AST-Base удовлетворяет этим требованиям лучше, чем более крупные энкодеры и более слабые базовые линии.

Итоговый вывод обзора существующих решений состоит в следующем. Для честного исследования необходимо оставить простые и средние модели в качестве экспериментальных ориентиров, потому что они показывают, насколько сложная архитектура действительно улучшает качество. Но основную теоретическую и практическую ставку следует делать на трансформерную модель со спектрограммными патчами и переносом обучения. Поэтому дальнейшая глава подробно рассматривает именно AST-Base, а глава 3 сравнивает ее с ручными признаками, ResNet18 и CRNN в едином экспериментальном протоколе.

1.3 Обзор датасетов

В качестве основного набора данных в работе используется ICBNI 2017 Respiratory Sound Database [1]. Набор содержит 920 аудиозаписей от 126 пациентов, около 5.5 часа звука и 6898 размеченных дыхательных циклов. В разметке каждого цикла указаны начало, окончание и два бинарных признака, по которым формируются классы `normal`, `crackle`, `wheeze` и `both`. Записи получены на разных устройствах и имеют разные частоты дискретизации, что делает набор полезным для проверки устойчивости конвейера обработки.

ICBNI важен для данной работы по нескольким причинам. Во-первых, он содержит разметку именно на уровне дыхательных циклов, а не только на уровне целой записи. Это позволяет формировать короткие сегменты и решать задачу классификации аудиофрагментов. Во-вторых, классы `crackle` и `wheeze` задаются через бинарные признаки, поэтому из них естественно получается четырехклассовая постановка. В-третьих, набор неоднороден по устройствам и частотам дискретизации, что усложняет задачу и делает проверку конвейера более реалистичной.

Для экспериментов важно, что ICBNI допускает пациент-независимое

разбиение. Если сегменты одного пациента попадут одновременно в train и test, модель может частично запомнить особенности пациента, устройства или условий записи. Это приведет к завышенной оценке качества. Поэтому в практической части используется разбиение по patient id. Такой подход строже, чем случайное разбиение сегментов, и лучше отражает способность модели переноситься на новые записи.

Ограничением ICBHI является небольшой объем данных по современным меркам глубокого обучения. Несмотря на 6898 размеченных циклов, редкие классы представлены существенно слабее большинства. Кроме того, записи отличаются длительностью и качеством. Это делает набор полезным для исследования методов балансировки и переноса обучения, но ограничивает возможность обучать крупные модели с нуля. Поэтому ICBHI хорошо согласуется с выбранной стратегией: использовать предварительно обученную AST-Base и дообучать ее на целевой разметке.

Кроме ICBHI, в области используются и другие наборы данных. SPRSound применяется как педиатрический бенчмарк дыхательных звуков [9]. HF_Lung_V1 ориентирован на более крупные задачи обнаружения событий и фаз дыхания. RespiratoryDatabase@TR содержит дополнительные дыхательные записи, а Coswara включает пользовательские записи дыхания и кашля [10]. Эти наборы полезны для анализа переносимости методов, однако для практической части выбран единый набор ICBHI, поскольку он содержит стандартную разметку дыхательных циклов и позволяет сравнить все подходы в одном конвейере.

SPRSound представляет интерес как пример набора, ориентированного на другую популяцию и другой сценарий записи. Педиатрические дыхательные звуки могут отличаться от взрослых записей по частотному профилю, длительности дыхательных циклов и уровню шума. Поэтому результаты, полученные на ICBHI, нельзя автоматически переносить на SPRSound. Тем не менее наличие такого набора важно для будущей проверки переносимости: модель, выбранная на ICBHI, может быть дообучена или протестирована на данных другого домена.

HF_Lung_V1 и сходные наборы, ориентированные на обнаружение событий, полезны для задач, где требуется не только классифицировать готовый сегмент, но и находить событие внутри длинной записи. Это более

сложная постановка, поскольку модель должна решать задачу локализации во времени. В настоящей работе задача ограничена классификацией уже выделенного дыхательного цикла, поэтому такие датасеты рассматриваются как перспективное направление, но не как основной источник экспериментов.

Coswara отличается от ICBNI тем, что включает пользовательские записи дыхания, кашля и голоса. Такие данные ближе к массовому сбору через потребительские устройства, но они сильнее зависят от условий записи, микрофона и поведения пользователя. Для дипломной работы на текущем этапе важнее иметь структурированную разметку дыхательных циклов, поэтому Coswara используется только как ориентир для обзора области.

Выбор единого набора данных упрощает контроль условий эксперимента. Все модели получают одинаковые сегменты, одинаковые разбиения и одинаковые целевые классы. Это особенно важно при сравнении ручных признаков, сверточных моделей и трансформерной архитектуры, поскольку различия в качестве должны быть связаны с моделью и признаками, а не с разными выборками.

При сравнении датасетов важно различать три уровня разметки. Первый уровень – разметка целой записи. В этом случае модель получает длинный аудиофайл и один общий класс. Второй уровень – разметка сегментов или дыхательных циклов. Именно этот вариант используется в работе. Третий уровень – покадровая или интервальная разметка событий, где необходимо определять начало и конец события. Для выбранной цели сегментная разметка является наиболее удобной: она позволяет строить воспроизводимые примеры фиксированной длины и использовать стандартные метрики классификации.

Таким образом, ICBNI выбран не потому, что он является самым большим набором данных, а потому, что он соответствует постановке работы. Он содержит размеченные дыхательные циклы, поддерживает четырехклассовую задачу, имеет неоднородные записи и позволяет сравнить разные архитектуры в едином конвейере. Остальные наборы важны для анализа внешней валидности и будущих экспериментов, но их использование потребовало бы отдельного согласования разметки, классов и про-

токолов оценки.

При работе с дыхательными датасетами важно учитывать не только число записей, но и способ формирования примеров для обучения. Одна длинная запись может содержать несколько дыхательных циклов, поэтому число исходных файлов и число обучающих сегментов различаются. Если разметка содержит интервалы дыхательных циклов, каждый интервал можно рассматривать как отдельный пример. Такой подход увеличивает число объектов, но требует аккуратного разбиения по пациентам. Иначе сегменты одной записи могут оказаться в разных выборках, что приведет к утечке информации.

Еще один важный аспект – согласованность классов. Разные наборы могут использовать разные таксономии: где-то выделяются только нормальные и аномальные записи, где-то отдельно размечаются *crackle* и *wheeze*, где-то присутствуют дополнительные типы дыхательных шумов. Поэтому перенос модели между датасетами не является механическим. Необходимо либо привести классы к общей схеме, либо обучать отдельную классификационную голову под каждый набор. В данной работе используется единая четырехклассовая схема, потому что она напрямую следует из разметки ICBNI и подходит для сравнения моделей.

Качество датасета также определяется уровнем шума и полнотой аннотаций. Если в записи присутствуют посторонние звуки, модель может получать противоречивые сигналы. Если границы дыхательных циклов размечены неточно, короткие события могут частично выходить за пределы сегмента. Если класс задан на уровне всего цикла, но событие занимает только малую часть этого цикла, модель должна научиться выделять слабый локальный признак на фоне остальной записи. Эти свойства объясняют, почему даже сравнительно небольшой датасет может быть сложным для классификации.

Таким образом, обзор датасетов показывает, что задача не сводится к выбору самого большого набора. Для исследовательской работы важнее соответствие датасета постановке, наличие сегментной разметки, возможность пациент-независимого разбиения и единая схема классов. По этим критериям ICBNI является подходящей основой для практической части, а остальные наборы формируют контекст для будущей проверки перенос-

симости.

1.4 Постановка задачи

Основная задача формулируется как многоклассовая классификация аудиосегмента:

$$x_i \rightarrow y_i, \quad y_i \in \{0, 1, 2, 3\}, \quad (1.1)$$

где x_i обозначает фрагмент дыхательной аудиозаписи, а y_i обозначает номер класса. В формуле (1.1) классам соответствуют значения: 0 – normal, 1 – crackle, 2 – wheeze, 3 – both.

Дополнительно такая постановка может быть сведена к бинарной классификации normal против non-normal, однако в данной работе основной результат оценивается именно в четырехклассовой постановке. Это позволяет отдельно анализировать качество распознавания разных типов акустических событий.

Работа решает задачу классификации аудиосегментов по разметке датасета. Модель не используется для самостоятельной постановки диагноза и не заменяет экспертную интерпретацию состояния пациента.

1.5 Математическая постановка

Пусть $x(t)$ – дискретизированный аудиосигнал дыхательного фрагмента, приведенный к частоте дискретизации 16 кГц и фиксированной длительности. Предобработка переводит сигнал в логарифмическую мел-спектрограмму по формуле (1.2):

$$X = \text{LogMel}(x), \quad (1.2)$$

где $X \in \mathbb{R}^{F \times T}$, F – число мел-каналов, T – число временных кадров. В работе используется $F = 128$.

Размеченный набор данных задается выражением (1.3):

$$D = \{(x_i, y_i)\}_{i=1}^N, \quad (1.3)$$

где N – число сегментов. Модель f_θ с параметрами θ возвращает вектор

вероятностей по формуле (1.4):

$$\hat{p}_i = \text{softmax}(f_\theta(X_i)). \quad (1.4)$$

Для обучения используется перекрестная энтропия. При дисбалансе классов применяется взвешенная функция потерь:

$$L = -\frac{1}{N} \sum_{i=1}^N w_{y_i} \log \hat{p}_{i,y_i}, \quad (1.5)$$

где w_{y_i} – вес класса, обратно пропорциональный его частоте в обучающей выборке. Формула (1.5) позволяет усилить вклад редких классов при обучении.

1.6 Метрики качества

Для оценки качества используются ассурасу, balanced ассурасу, макро F1, weighted F1, полнота по каждому классу и матрица ошибок. Ассурасу показывает общую долю правильных ответов, но на несбалансированных данных может быть завышена за счет большинства. Balanced ассурасу усредняет полноту по классам и поэтому лучше отражает качество на редких классах:

$$\text{BA} = \frac{1}{C} \sum_{c=1}^C \text{Recall}_c. \quad (1.6)$$

Макро F1 усредняет F1-меру по классам без учета их частоты:

$$\text{MacroF1} = \frac{1}{C} \sum_{c=1}^C F1_c. \quad (1.7)$$

Формулы (1.6) и (1.7) особенно важны для выбранной задачи, поскольку класс `both` встречается существенно реже остальных классов.

Ассурасу остается полезной метрикой, но ее нельзя использовать как единственный критерий. Если тестовая выборка содержит много сегментов `normal`, модель может получить приемлемую ассурасу, почти не распознавая `both`. В прикладном смысле это нежелательно: редкие классы как раз являются наиболее важными для анализа качества классификатора. Поэтому ассурасу в работе рассматривается как дополнительная агрегиро-

ванная характеристика, а не как основной показатель.

Balanced accuracy устраняет часть этой проблемы, поскольку считает recall каждого класса и затем усредняет эти значения. Если модель хорошо распознает `normal`, но плохо распознает `wheeze` и `both`, balanced accuracy будет ниже обычной accuracy. Это делает метрику удобной для сравнения моделей на несбалансированных данных. Однако balanced accuracy учитывает только полноту и не учитывает точность предсказаний. Поэтому ее следует рассматривать вместе с F1-метриками.

Macro F1 усредняет F1 по классам без учета частоты класса. В результате редкий класс `both` имеет такой же вес, как частый класс `normal`. Это полезно для честной оценки качества по всем классам, но делает метрику более строгой. Если модель сильно ошибается на одном классе, macro F1 заметно снижается. Именно поэтому macro F1 используется для выбора лучшего checkpoint: она не позволяет модели улучшать качество только на большинстве.

Weighted F1, напротив, учитывает частоту классов. Эта метрика ближе к ожидаемому среднему качеству на тестовом распределении, но может маскировать слабость редких классов. Например, если модель хорошо классифицирует `normal` и `crackle`, weighted F1 может быть достаточно высоким даже при низком recall класса `both`. Поэтому в отчете weighted F1 дополняет macro F1, но не заменяет его.

Полнота по каждому классу нужна для анализа ошибок. Она показывает, какая доля объектов каждого истинного класса была найдена моделью. Для выбранной задачи это особенно важно, поскольку разные классы имеют разную акустическую природу. `Crackle` связан с короткими дискретными событиями, `wheeze` – с более протяженными тональными компонентами, а `both` объединяет оба признака. Если смотреть только на одну агрегированную метрику, невозможно понять, какая именно акустическая категория вызывает проблемы.

Матрица ошибок используется как более подробное представление результата. Она показывает не только факт ошибки, но и направление ошибки: например, путает ли модель `both` с `crackle`, `wheeze` или `normal`. Такая информация важна для последующих улучшений. Если смешанный класс чаще относится к одному из одиночных классов, это ука-

зывает на необходимость усиливать признаки совместного присутствия событий. Если редкие события часто относятся к `normal`, это говорит о недостаточной чувствительности модели.

Итоговый протокол оценки должен использовать несколько метрик одновременно. Accuracy показывает общую долю правильных ответов. Balanced accuracy и macro F1 оценивают устойчивость качества по классам. Weighted F1 показывает среднее качество с учетом тестового распределения. Per-class recall и матрица ошибок позволяют интерпретировать слабые места модели. Такой набор метрик соответствует характеру задачи, где данные несбалансированы, классы акустически неоднородны, а редкие события имеют большое значение для анализа качества.

Для более полной интерпретации F1-метрик полезно помнить, что F1 объединяет precision и recall. Precision показывает, насколько часто предсказания выбранного класса являются правильными. Recall показывает, какая доля истинных объектов класса была найдена. В задаче дыхательных звуков эти величины могут расходиться. Например, модель может редко предсказывать `both`, но почти всегда быть права в этих редких предсказаниях; тогда precision будет высоким, а recall низким. И наоборот, модель может часто предсказывать редкий класс, повышая recall, но создавая много ложных срабатываний.

Macro F1 полезна тем, что штрафует оба типа проблем. Если для какого-то класса низкая precision или низкая recall, F1 этого класса снижается. При усреднении по классам это сразу отражается на итоговой macro F1. Поэтому macro F1 хорошо подходит для выбора модели, когда требуется не просто максимизировать число правильных ответов, а сохранять качество на всех классах.

Валидационная метрика используется не только для итогового сравнения, но и для выбора checkpoint во время обучения. В данной работе предпочтение отдается validation macro F1, поскольку она лучше согласуется с целью распознавания всех классов. Если выбирать checkpoint по train loss или обычной validation accuracy, можно получить модель, хорошо подстроенную под частые классы, но слабую на редких событиях. Поэтому связь между метрикой выбора checkpoint и итоговой метрикой качества является важной частью экспериментального протокола.

Наконец, метрики следует рассматривать вместе с графиками обучения. Если `train loss` быстро уменьшается, а `validation loss` растёт, это указывает на переобучение. Если при этом `validation macro F1` некоторое время остается высокой, значит модель сохраняет полезное качество, но требует выбора подходящей эпохи. Поэтому в практической части анализируются не только итоговые таблицы, но и динамика обучения AST-Base.

Глава 2. Теоретическое описание выбранного решения

2.1 Общий конвейер AST-Base

Во второй главе рассматривается только выбранная основная архитектура AST-Base. Другие модели используются в работе как экспериментальные базовые линии и подробно анализируются в практической главе. Основное теоретическое решение строится вокруг преобразования дыхательного аудиофрагмента в логарифмическую мел-спектрограмму и последующей классификации этой спектрограммы трансформерной моделью.

Полный конвейер обработки показан на рисунке 2.1. Он начинается с сырой аудиозаписи, затем выделяется размеченный дыхательный цикл, сигнал приводится к фиксированной длительности, строится логарифмическая мел-спектрограмма, после чего AST-Base выполняет классификацию одного из четырех классов.




Рис. 2.1: Конвейер классификации дыхательного аудиосегмента на основе AST-Base

Рисунок 2.1 отражает важное свойство реализации: модель не работает с исходным WAV-файлом напрямую. Входом AST является двумерное частотно-временное представление, поэтому качество всей системы зависит и от параметров предварительной обработки, и от параметров трансформерной части.

2.2 Требования к входному аудиофрагменту

Выбранное решение ориентировано не на классификацию всей исходной записи, а на классификацию отдельного размеченного дыхательного цикла. Такое ограничение важно для корректной постановки задачи.

В исходной базе одна запись может содержать несколько циклов, разные паузы, шумы контакта микрофона и участки, не относящиеся к дыхательному событию. Если подавать в модель всю запись целиком, то один входной пример будет смешивать несколько акустических состояний и не будет однозначно соответствовать целевой метке. Поэтому на первом этапе используется разметка временных границ циклов, а каждый цикл рассматривается как самостоятельный объект классификации.

Для модели AST-Base требуется фиксированная форма входного тензора. Это требование связано не только с размером пакета при обучении, но и с позиционными вложениями трансформера. Последовательность токенов должна иметь ограниченную максимальную длину, иначе память GPU будет расходоваться квадратично по числу токенов в механизме самовнимания. Поэтому в работе выбран единый временной интервал 8 секунд. Он достаточно велик, чтобы вместить большинство дыхательных циклов, и одновременно не приводит к чрезмерному росту числа временных кадров в спектрограмме.

Преобразование к монофоническому сигналу также является частью входного протокола. В задаче не используется пространственная информация между каналами, а исходные записи датасета рассматриваются как одномерные временные сигналы. Если запись содержит несколько каналов, они должны быть сведены к одному каналу до вычисления спектрограммы. В результате модель получает сопоставимые примеры, а различия между объектами определяются дыхательным событием, устройством записи, шумом и пациентом, но не произвольной конфигурацией каналов.

Нормализация частоты дискретизации к 16 кГц согласована с предварительно обученной AST-Base и с практическим диапазоном дыхательных звуков. Более высокая частота дискретизации увеличила бы объем вычислений и число спектральных отсчетов, но не дала бы прямого преимущества для большинства низко- и среднечастотных дыхательных паттернов. Более низкая частота могла бы привести к потере высокочастотных составляющих, которые полезны для распознавания коротких хрипов и шумовых компонентов. Поэтому 16 кГц используется как компромисс между сохранением информативного диапазона и вычислительной стоимостью.

Короткие циклы дополняются циклическим повторением, а длин-

ные фрагменты обрезаются. Циклическое дополнение предпочтительнее простого заполнения нулями, потому что нулевые участки создают искусственные области тишины и меняют статистику log-mel спектрограммы. При повторении короткого цикла сохраняется его спектральная структура, хотя появляется риск усиления периодичности. Этот риск учитывается в третьей главе при анализе ошибок, поскольку часть неправильных ответов может быть связана не только с архитектурой, но и с процедурой приведения длительности.

2.3 Преобразование аудиосигнала

Пусть $x[n]$ – дискретный монофонический сигнал, полученный после ресемплирования исходной записи к 16 кГц. Для выделенного дыхательного цикла выполняется приведение к фиксированной длине:

$$\tilde{x} = \text{FixLength}(x, 8 \cdot 16000), \quad (2.1)$$

где FixLength означает обрезание длинного фрагмента или циклическое дополнение короткого фрагмента. Формула (2.1) задает вход одинаковой длины для всех последующих операций.

Далее вычисляется кратковременное преобразование Фурье:

$$S(m, k) = \sum_{n=0}^{N-1} \tilde{x}[n + mh] w[n] e^{-j2\pi kn/N}, \quad (2.2)$$

где $w[n]$ – оконная функция, h – шаг окна, m – номер временного кадра, k – частотный индекс. В работе используется окно 25 мс и шаг 10 мс.

Спектр мощности проецируется на мел-шкалу и логарифмируется:

$$X = \log(M|S|^2 + \epsilon), \quad (2.3)$$

где M – матрица из 128 мел-фильтров, ϵ – малая константа для численной устойчивости. Затем выполняется нормализация:

$$X_{\text{norm}} = \frac{X - \mu_X}{\sigma_X + \epsilon}. \quad (2.4)$$

Формулы (2.2)–(2.4) задают входное представление AST-Base. Схематиче-

ский вид такого представления приведен на рисунке 2.2.

Параметры предварительной обработки в работе выбраны так, чтобы сохранить локальные временные события и одновременно получить вход, совместимый с AST-Base. Основные значения приведены в таблице 2.1. Эта таблица связывает теоретические обозначения из формул (2.1)–(2.4) с конкретными параметрами практической реализации.

Таблица 2.1: Параметры формирования входной log-mel спектрограммы

Параметр	Значение	Назначение
Частота дискретизации	16 кГц	единый временной масштаб для всех записей
Длительность фрагмента	8 с	фиксированная длина входа модели
Окно STFT	25 мс	локальная оценка спектрального состава
Шаг STFT	10 мс	сохранение временной детализации событий
Число mel-каналов	128	компактное частотное представление
Максимальная длина AST	1024 кадра	ограничение длины входной последовательности

Окно 25 мс задает локальный участок, внутри которого сигнал считается достаточно стационарным для спектрального анализа. Для дыхательных звуков это приближение не является точным во всех случаях, но оно практически удобно: окно достаточно короткое, чтобы фиксировать кратковременные изменения, и достаточно длинное, чтобы получить устойчивую оценку спектра. Шаг 10 мс дает перекрытие соседних окон и снижает риск пропуска коротких событий между кадрами.

Использование 128 mel-каналов задает вертикальное разрешение спектрограммы. При меньшем числе каналов модель получила бы более грубое частотное описание, что особенно нежелательно для протяженных тональных компонентов класса wheeze. При существенно большем числе каналов увеличивался бы размер входа без гарантии роста качества,

потому что объем обучающей выборки ограничен. Поэтому выбранное значение является практическим компромиссом между детализацией и устойчивостью обучения.

Логарифмирование энергии в формуле (2.3) уменьшает динамический диапазон признаков. Без этой операции сильные компоненты спектра могли бы доминировать над слабыми, а короткие дыхательные события терялись бы на фоне общей энергии записи. После логарифмирования различия становятся ближе к масштабу, в котором их удобнее обрабатывать линейными проекциями и механизмом внимания. Последующая нормализация в формуле (2.4) приводит к более стабильному распределению и уменьшает зависимость обучения от абсолютной громкости записи.




Рис. 2.2: Схематическое частотно-временное представление дыхательного фрагмента после log-mel преобразования

На рисунке 2.2 показана не конкретная запись из датасета, а схема распределения энергии во времени и по мел-каналам. Для дыхательных событий важны как короткие локальные всплески, характерные для crackle, так и более протяженные частотные области, характерные для wheeze.

2.4 Акустические признаки целевых классов

Четыре класса задачи различаются не только меткой, но и типом частотно-временного рисунка. Класс `normal` соответствует сегментам без размеченных дополнительных событий. Его спектрограмма обычно не содержит ярко выраженных коротких всплесков или устойчивых узкополосных участков. При этом нормальный класс не является полностью однородным: громкость, фаза дыхания, положение микрофона и пациентские различия могут сильно менять общий вид спектрограммы.

Класс `crackle` связан с короткими дискретными событиями. В `logmel` представлении такие события проявляются как локальные всплески энергии, которые могут занимать небольшое число временных кадров. Для распознавания этого класса важна временная детализация, поэтому шаг STFT и патчевое разбиение не должны чрезмерно сглаживать сигнал. Если короткое событие попадает на границу патча, модель должна восстановить его значение через соседние токены и последующее самовнимание.

Класс `wheeze` имеет другую природу: он чаще представлен более протяженными тональными компонентами. В спектрограмме такие компоненты выглядят как относительно устойчивые частотные области на протяжении части дыхательного цикла. Для этого класса важна способность модели связывать удаленные временные участки и оценивать длительность паттерна. Именно здесь трансформерная архитектура полезнее локального сверточного блока, потому что самовнимание может сопоставлять разные части спектрограммы без последовательного накопления контекста.

Класс `both` объединяет признаки `crackle` и `wheeze`. Он сложен по двум причинам. Во-первых, это редкий класс, поэтому модель получает меньше разнообразных примеров. Во-вторых, он не описывается одним простым акустическим шаблоном: короткие всплески и протяженные тональные компоненты могут находиться в разных местах дыхательного цикла и иметь разную интенсивность. Для такой метки особенно важно, чтобы классификатор не сводил решение только к самому сильному локальному признаку.

Из этого следует, что выбранная архитектура должна одновременно учитывать локальные и глобальные свойства спектрограммы. Локальные свойства нужны для коротких событий, глобальные – для оценки распределения энергии по всему дыхательному циклу и для совместного анализа разных типов признаков. AST-Base удовлетворяет этому требованию за счет `patch embedding`, который выделяет локальные участки, и `self-attention`, который связывает их в единую последовательность.

2.5 Патчи спектрограммы и вход трансформера

AST-Base рассматривает нормализованную спектрограмму как двумерную сетку, которая разбивается на патчи. Каждый патч разворачивается

в вектор и линейно проецируется в пространство скрытой размерности:

$$z_i = W_p \text{vec}(P_i) + b_p, \quad (2.5)$$

где P_i – i -й патч спектрограммы, W_p и b_p – параметры линейного слоя patch embedding. Формула (2.5) переводит локальный участок спектрограммы в токен трансформера.

К последовательности токенов добавляется специальный классификационный токен и позиционные вложения:

$$Z_0 = [z_{\text{cls}}; z_1; z_2; \dots; z_N] + E_{\text{pos}}. \quad (2.6)$$

Выражение (2.6) важно, потому что без позиционных вложений модель не различала бы порядок патчей по времени и частоте. Схема формирования входной последовательности показана на рисунке 2.3.




Рис. 2.3: Разбиение log-mel спектрограммы на патчи и формирование последовательности токенов AST

Рисунок 2.3 показывает, что каждый токен соответствует локальному частотно-временному участку. При этом дальнейший механизм самовнимания позволяет каждому токenu учитывать информацию из остальных участков спектрограммы.

Патчевое представление является переходом от аудиозадачи к задаче обработки последовательности. В отличие от классической обработки спектрограммы сверточной сетью, AST-Base не накладывает жесткое предположение, что информация должна распространяться только через локальные соседства. После формирования токенов любой участок спектрограммы может быть связан с любым другим участком уже в одном слое внимания. Это особенно важно для дыхательных циклов, где события мо-

гут располагаться в начале, середине или конце фрагмента.

Позиционные вложения в формуле (2.6) выполняют две функции. Во-первых, они задают временной порядок патчей, без которого модель не отличала бы ранний участок дыхательного цикла от позднего. Во-вторых, они задают частотное положение, что необходимо для различения низко- и высокочастотных компонентов. Для дыхательных звуков это существенно, потому что разные типы событий могут занимать разные диапазоны mel-каналов.

Предварительно обученная AST-Base была получена на общей задаче аудиоклассификации [2]. Поэтому ее patch embedding и позиционные представления уже содержат полезное приближение к обработке спектрограмм. Однако вход в текущей задаче имеет собственную длительность и собственное распределение энергии. При дообучении модель адаптирует параметры так, чтобы токены дыхательных спектрограмм давали разделимые представления четырех целевых классов. Это не отменяет пользы предварительного обучения, но делает его начальной точкой, а не финальным решением.

Максимальная длина входа AST ограничена 1024 временными позициями. При длительности 8 секунд и шаге 10 мс фактическое число кадров остается внутри этого предела. Если бы длительность была существенно увеличена, пришлось бы либо усекать спектрограмму, либо менять конфигурацию модели, либо использовать агрегацию фрагментов. В данной работе такие усложнения не вводятся, потому что цель состоит в сравнительно простой и воспроизводимой схеме дообучения выбранной архитектуры.

2.6 Блок самовнимания

Основной вычислительный блок AST-Base состоит из нормализации, многоголового самовнимания, остаточного соединения и полносвязной MLP-части. Для входной последовательности Z строятся матрицы запросов, ключей и значений:

$$Q = ZW_Q, \quad K = ZW_K, \quad V = ZW_V. \quad (2.7)$$

Механизм внимания вычисляется по формуле:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d}} \right) V. \quad (2.8)$$

Формулы (2.7) и (2.8) описывают, как модель оценивает связи между всеми патчами спектрограммы.

Один блок трансформера задается выражениями:

$$Z'_l = Z_{l-1} + \text{MHSA}(\text{LN}(Z_{l-1})), \quad (2.9)$$

$$Z_l = Z'_l + \text{MLP}(\text{LN}(Z'_l)). \quad (2.10)$$

Структура блока показана на рисунке 2.4. Остаточные соединения в формулах (2.9) и (2.10) помогают сохранять исходную информацию токена и стабилизируют обучение глубокой модели.




Рис. 2.4: Структура блока трансформера в AST-Base

Рисунок 2.4 иллюстрирует, что блок не только смешивает информацию между токенами через самовнимание, но и нелинейно преобразует

каждый токен через MLP. За счет повторения таких блоков AST-Base формирует глобальное представление дыхательного фрагмента.

Многоголовое внимание расширяет формулу (2.8): вместо одной матрицы внимания вычисляется несколько параллельных голов. Каждая голова имеет собственные проекции W_Q , W_K и W_V , поэтому может выделять разные типы связей между токенами. Одна голова может быть полезна для локальных соседних участков, другая – для повторяющихся временных паттернов, третья – для сопоставления частотных областей. После этого результаты голов объединяются и снова проецируются в скрытое пространство модели.

Для дыхательных спектрограмм такая схема имеет практический смысл. Если короткий crackle выражен только в нескольких кадрах, он может быть слабым относительно общего дыхательного шума. Механизм внимания позволяет классификационному токenu усилить вклад этих кадров, если они статистически важны для метки. Если же присутствует wheeze, модель может учитывать длительный участок спектрограммы и не ограничиваться одним локальным максимумом энергии.

LayerNorm в формулах (2.9) и (2.10) стабилизирует распределение скрытых состояний. Это важно при полном дообучении pretrained-модели, потому что входная область дыхательных звуков уже отличается от исходной области AudioSet. Остаточные соединения позволяют не разрушать полезные признаки, полученные на ранних слоях, и уменьшают риск деградации представления при прохождении через глубокую последовательность блоков.

MLP-часть блока выполняет нелинейное преобразование каждого токена после обмена информацией через внимание. Если самовнимание отвечает за смешивание контекста, то MLP уточняет признаки внутри каждого положения последовательности. В результате один слой трансформера можно рассматривать как две последовательные операции: сначала модель решает, какие токены должны взаимодействовать, затем преобразует обновленные токены в более подходящее пространство признаков.

2.7 Адаптация предварительно обученной AST-Base

AST-Base была предложена как трансформерная модель для классификации аудио по спектрограммам [2]. Ее практическая ценность в данной работе связана с переносом обучения: модель уже обучалась на большом наборе разнообразных аудиособытий AudioSet [8]. Это позволяет не начинать обучение с случайных признаков, что особенно важно при ограниченном числе размеченных дыхательных циклов.

Перенос обучения используется в виде полной замены классификационной головы и последующего дообучения всех параметров. Замена головы необходима, потому что исходный checkpoint решает задачу с другим набором классов. Новая голова получает четыре выхода, соответствующие классам *normal*, *crackle*, *whoeeze* и *both*. Остальные параметры инициализируются из *pretrained checkpoint*, поэтому модель начинает обучение с уже сформированным спектральным представлением.

Альтернативой было бы заморозить *backbone* и обучать только классификационную голову. Такой режим дешевле и снижает риск переобучения, но он ограничивает адаптацию к дыхательным сигналам. В данной работе *backbone* не замораживается, поскольку акустическая область отличается от общей аудиоклассификации: дыхательные события слабее, короче и чаще зависят от условий записи. Полное дообучение позволяет менять не только финальную линейную границу классов, но и сами признаки, на которых строится это разделение.

При этом полное дообучение требует осторожного *learning rate*. Слишком большой шаг оптимизатора мог бы быстро разрушить *pretrained*-представления, а слишком маленький привел бы к слабой адаптации. Поэтому используется значение $5 \cdot 10^{-5}$, характерное для аккуратного *fine-tuning* трансформерных моделей. *Weight decay* ограничивает рост весов и работает как регуляризация, что полезно при небольшой и несбалансированной выборке.

Выбранный подход можно описать как *domain-specific fine-tuning*. Общие аудиопризнаки используются как начальное знание, но итоговая модель оптимизируется под конкретное распределение дыхательных циклов. Это соответствует практической цели работы: не доказать универсальность AST для любых аудиозадач, а получить воспроизводимую модель

для заданной четырехклассовой классификации.

2.8 Классификационная голова и перенос обучения

После последнего блока трансформера используется представление классификационного токена $z_{\text{cls}}^{(L)}$. На его основе вычисляются логиты четырех классов:

$$o = W_c \text{LN}(z_{\text{cls}}^{(L)}) + b_c, \quad (2.11)$$

$$\hat{p} = \text{softmax}(o). \quad (2.12)$$

Формулы (2.11) и (2.12) задают финальную классификационную часть модели.

В реализации используется предварительно обученный checkpoint AST-Base, дообученный на AudioSet. Его исходная классификационная голова, обученная на AudioSet-классах [8], заменяется новой головой на четыре класса дыхательных событий. При этом остальная часть AST-Base дообучается полностью, то есть параметры backbone не замораживаются.

Причина выбора полного дообучения состоит в том, что дыхательные записи отличаются от общей аудиоклассификации. Предварительное обучение дает полезные низко- и среднеуровневые признаки спектрограмм, но модель должна адаптировать распределение внимания и итоговое представление к коротким дыхательным событиям. Ограничение по размеру модели соблюдается: выбранная AST-Base содержит 86м параметров, что меньше 100 млн.

Классификационный токен используется как агрегированное представление всего фрагмента. В отличие от усреднения всех патчей, такой подход позволяет модели обучить специальный токен, который собирает информацию, наиболее полезную для классификации. Через слои самовнимания этот токен взаимодействует с патчами спектрограммы и постепенно накапливает сведения о локальных и глобальных признаках.

Финальная softmax-вероятность в формуле (2.12) используется для выбора наиболее вероятного класса, однако при анализе качества важны не только максимальные вероятности. Если модель часто путает both с crackle или wheeze, то такая ошибка может быть скрыта в общей ассигасу, но проявится в per-class recall и macro F1. Поэтому теоретическое описание классификационной головы напрямую связано с выбором

метрик в третьей главе.

2.9 Функция потерь и учет дисбаланса

В обучающей выборке классы распределены неравномерно: `normal` представлен 2597 сегментами, а `both` – только 340 сегментами. Поэтому используется взвешенная перекрестная энтропия:

$$L = -\frac{1}{B} \sum_{i=1}^B w_{y_i} \log \hat{p}_{i,y_i}, \quad (2.13)$$

где B – размер пакета, w_{y_i} – вес класса, обратно пропорциональный его частоте. Формула (2.13) увеличивает вклад ошибок на редких классах.

Дополнительно применяется взвешенная выборка. Для каждого обучающего примера задается вероятность попадания в пакет, связанная с весом его класса. Поэтому редкие классы чаще появляются во время обучения, а модель получает больше градиентных шагов, связанных с `wheeze` и `both`. Совместная схема учета дисбаланса показана на рисунке 2.5.




Рис. 2.5: Учет дисбаланса классов при обучении AST-Base

Рисунок 2.5 показывает, что веса классов используются в двух местах: при формировании обучающих пакетов и при вычислении функции потерь. Такая схема не устраняет дисбаланс полностью, но повышает внимание модели к редким классам.

Использование только `weighted sampler` без взвешенной функции потерь изменило бы состав пакетов, но не изменило бы цену ошибки внутри конкретного пакета. Использование только `weighted loss`, наоборот, усилило бы градиент от редких классов, но редкие примеры появлялись бы в

обучении реже. Совместное применение двух механизмов делает обучение более направленным на `minority`-классы, хотя и может повысить нестабильность метрик на валидации.

Особенно важен класс `both`. Его редкость означает, что модель может получить приемлемый `weighted F1` даже при слабом качестве этого класса, если хорошо распознает `normal`. Поэтому `macro F1` используется не только как отчетная метрика, но и как критерий выбора лучшего `checkpoint`. Такой выбор согласован с целью получить модель, которая не игнорирует малочисленные классы.

2.10 Регуляризация и аугментации спектрограмм

Для аудиозадач регуляризация может выполняться как на уровне исходного сигнала, так и на уровне спектрограммы. В данной работе основная теоретическая схема допускает использование спектрограммных аугментаций, близких к SpecAugment [6]: маскирование временных и частотных областей. Такие преобразования не меняют целевую метку, но заставляют модель опираться не на один узкий участок, а на более устойчивое распределение признаков.

Временное маскирование скрывает часть кадров спектрограммы. Для класса `wheeze` это может предотвращать ситуацию, когда модель запоминает один конкретный временной участок вместо общего протяженного паттерна. Для класса `crackle` маскирование требует осторожности: если скрыть единственный короткий всплеск, пример может стать неоднозначным. Поэтому агрессивность временных масок должна быть ограниченной.

Частотное маскирование скрывает часть `mel`-каналов. Оно полезно против переобучения на конкретный частотный профиль устройства записи или пациента. Если модель видит один и тот же класс при частично скрытых частотах, она учится использовать более широкий контекст. Однако слишком широкие частотные маски могут повредить распознаванию `wheeze`, поскольку этот класс часто связан с выраженными частотными полосами.

Weight decay в оптимизаторе AdamW является параметрической регуляризацией. Он не меняет входные данные, но ограничивает величину

весов и снижает склонность модели к запоминанию обучающей выборки. Для AST-Base это особенно важно из-за большого числа параметров: 86м параметров существенно больше, чем число уникальных пациентов и дыхательных циклов в используемой выборке.

Еще одним источником регуляризации является выбор лучшего checkpoint по валидационной макро F1, а не по минимальному train loss. Если модель начинает переобучаться, train loss может продолжать снижаться, но качество на валидации перестает расти. Поэтому критерий сохранения checkpoint фактически ограничивает использование переобученных состояний модели.

2.11 Организация обучения и валидации

Обучающая, валидационная и тестовая части формируются с учетом patient-independent split. Это означает, что циклы одного пациента не должны одновременно попадать в обучение и оценку. Такое правило важнее случайного разбиения по отдельным сегментам, потому что дыхательные записи одного пациента могут иметь общие свойства: устройство, условия записи, тембр дыхания, уровень шума и повторяющиеся паттерны.

Если игнорировать patient-independent split, модель могла бы частично узнавать пациента, а не обобщать признаки класса. В этом случае оценка на валидации была бы завышенной и хуже отражала бы работу на новых пациентах. Поэтому теоретически корректная валидация должна отделять не только файлы, но и источники записей. В данной работе это условие задано в конфигурации разбиения данных.

Размер пакета 8 выбран с учетом памяти GPU и размера AST-Base. Для трансформеров память зависит от числа токенов и числа слоев, а механизм внимания имеет квадратичную сложность по длине последовательности. Увеличение batch size могло бы стабилизировать градиенты, но потребовало бы больше памяти. Уменьшение batch size сделало бы обучение более шумным. Поэтому выбранное значение является практическим компромиссом.

Обучение проводится 50 эпох. Это число задает верхнюю границу процесса, но итоговая модель выбирается не по последней эпохе, а по лучшему значению макро F1 на валидации. Такой подход важен для больших

pretrained-моделей: после некоторого момента дальнейшее обучение может улучшать подгонку train-выборки, но ухудшать способность к обобщению.

Для воспроизводимости фиксируется seed 42. Полная битовая воспроизводимость в GPU-обучении не всегда гарантируется из-за недетерминированных операций, но фиксированный seed уменьшает разброс, связанный с начальным порядком данных и стохастическими компонентами обучения. В отчете это важно для интерпретации результатов: сравнение моделей должно отражать архитектурные различия, а не случайные особенности одного запуска.

2.12 Параметры обучения и ограничения

AST-Base обучается 50 эпох с размером пакета 8. Оптимизатор AdamW использует learning rate $5 \cdot 10^{-5}$ и weight decay 10^{-4} . Лучший checkpoint выбирается по macro F1 на валидационной выборке, поскольку эта метрика не позволяет большинству класса `normal` полностью доминировать при выборе модели.

Основные ограничения выбранного решения связаны с предварительной обработкой, шумом и редкими классами. Длина 8 секунд удобна для единого входа, но короткие дыхательные циклы приходится повторять циклическим дополнением. Разные устройства записи могут менять спектральный профиль сигнала. Наконец, класс `both` остается самым трудным, поскольку он редко встречается и объединяет признаки двух разных акустических событий.

Вычислительная сложность AST-Base определяется не только числом параметров, но и длиной токеной последовательности. Для каждого слоя attention необходимо вычислить матрицу попарных взаимодействий между токенами. Поэтому увеличение длительности аудио или уменьшение шага STFT напрямую повышает стоимость обучения. В выбранной конфигурации длительность 8 секунд, шаг 10 мс и ограничение 1024 кадра удерживают задачу в пределах доступной памяти.

Еще одно ограничение связано с интерпретируемостью. Attention-карты могут показать, какие области спектрограммы получили высокий вес, но они не являются полноценным объяснением решения модели.

Высокое внимание к определенному патчу не всегда означает причинную важность этого участка. Поэтому в практической части основная оценка строится на метриках качества и матрице ошибок, а не на визуальной интерпретации attention.

Наконец, выбранное решение зависит от качества разметки. Если границы дыхательного цикла заданы неточно, в 8-секундный фрагмент может попасть лишняя пауза или часть соседнего события. Если метка класса неоднозначна, модель получает противоречивый обучающий сигнал. Архитектура AST-Base не устраняет эти проблемы автоматически; она только дает более выразительный механизм обработки спектрограмм. Поэтому качество итоговой системы ограничивается не только моделью, но и исходной разметкой, процедурой сегментации и репрезентативностью выборки.

Таким образом, глава описывает выбранное решение как полный конвейер: от нормализации входного аудио и построения log-mel спектрограммы до patch embedding, самовнимания, классификационной головы и процедуры fine-tuning. Практическая глава далее проверяет, насколько такая теоретическая схема реализуется в метриках на валидационной и тестовой выборках.

Глава 3. Практическая реализация и анализ результатов

3.1 Среда и инструменты

Практическая часть реализована на Python 3.11. Для обучения нейросетевых моделей используются PyTorch, torchaudio и torchvision. Для загрузки и ресемплирования аудио применяются soundfile и librosa. Для классических моделей и метрик используется scikit-learn. Для визуализации матриц ошибок и кривых обучения используются matplotlib и seaborn. Для загрузки AST используется библиотека transformers.

Разработка выполняется в локальном каталоге проекта, а запуск команд обучения выполняется на сервере ЈН в выделенной conda-среде проекта. Синхронизация проекта выполняется через Mutagen. Такой режим выбран из-за необходимости запускать обучение на GPU и хранить датасеты, веса моделей и тяжелые артефакты вне домашнего каталога сервера.

3.2 Подготовка данных

Сырой набор данных ICBNI размещается в серверном каталоге датасетов проекта. Индекс сегментов строится модулем `src.data.index`. Для каждого WAV-файла находится одноименный TXT-файл с разметкой дыхательных циклов. Каждая строка разметки содержит начало, окончание и два бинарных признака наличия `crackle` и `wheeze`. По этим признакам формируется один из четырех классов.

Разбиение на обучающую, валидационную и тестовую выборки выполняется пациент-независимо. Это снижает риск того, что модель будет запоминать особенности конкретного пациента вместо акустических признаков класса. Используемые параметры подготовки данных приведены в таблице 3.1.

Таблица 3.1: Параметры подготовки данных

Параметр	Значение
Частота дискретизации	16000 Гц
Фиксированная длительность сегмента	8 с
Число мел-каналов	128
Окно STFT	25 мс
Шаг STFT	10 мс
Разбиение	70% / 15% / 15%
Случайное зерно	42
Тип разбиения	пациент-независимое

После построения индекса получено 6898 сегментов. Распределение сегментов по выборкам приведено в таблице 3.2.

Таблица 3.2: Распределение сегментов по выборкам

Выборка	Число сегментов
Обучающая	4915
Валидационная	991
Тестовая	992
Итого	6898

Распределение классов в обучающей и тестовой выборках приведено в таблице 3.3. Из таблицы видно, что класс `both` представлен существенно меньшим числом сегментов, чем класс `normal`.

Таблица 3.3: Распределение классов в обучающей и тестовой выборках

Класс	Обучающая выборка	Тестовая выборка
<code>normal</code>	2597	559
<code>crackle</code>	1323	187
<code>wheeze</code>	655	148
<code>both</code>	340	98

То же распределение в графическом виде показано на рисунке 3.1. График наглядно показывает, что обучающая выборка ориентирована на

большинство `normal`, а редкий класс `both` требует специальных приемов балансировки.




Рис. 3.1: Распределение классов в обучающей и тестовой выборках

3.3 Экспериментальные конфигурации

В работе проведены базовые эксперименты с несколькими семействами моделей и отдельная проверка влияния несбалансированной обучающей выборки для AST-Base. Их назначение приведено в таблице 3.4. Дополнительно в коде подготовлены конфигурации `focal loss` и аугментации меньших классов, чтобы расширять сравнение без изменения общего протокола обучения.

Таблица 3.4: Экспериментальные конфигурации

Эксперимент	Вход	Модель	Назначение
Baseline ML	MFCC/statistics	Logistic regression	Нижняя граница
CNN	Log-mel	ResNet18	Локальные признаки
CRNN	Log-mel	CNN + GRU	Временная структура
Transformer raw	Log-mel	AST-Base	Без балансировки
Transformer weighted	Log-mel	AST-Base	Основная модель

Для классической модели используется `class_weight=balanced`. Для ResNet18, CRNN и основной AST-Base используются `weighted sampler` и `weighted cross entropy`. Контрольный AST-Base обучается на той же исходной выборке, но без `weighted sampler` и без весов классов в функции

потерь. ResNet18 и CRNN обучаются 30 эпох с размером пакета 16 и learning rate $3 \cdot 10^{-4}$. AST-Base обучается с размером пакета 8 и learning rate $5 \cdot 10^{-5}$; лучший checkpoint выбирается по validation macro F1.

Размеры нейросетевых моделей приведены на рисунке 3.2. AST-Base существенно крупнее ResNet18 и CRNN, однако остается меньше ограничения 100 млн параметров.




Рис. 3.2: Число параметров нейросетевых моделей

3.4 Метрики и протокол оценки

Все модели оцениваются на одной и той же тестовой выборке. Основными метриками являются macro F1 и balanced accuracy, поскольку они устойчивее к дисбалансу классов, чем accuracy. Weighted F1 дополнительно показывает качество с учетом фактического распределения классов. Полнота по каждому классу используется для анализа того, какие акустические события распознаются хуже.

Для нейросетевых моделей в процессе обучения сохраняется лучший checkpoint по macro F1 на валидационной выборке. После этого checkpoint повторно оценивается на тестовой выборке. Для каждого запуска сохраняются конфигурация, метрики, сведения о числе параметров, матрица ошибок и кривые обучения.

Для основной модели AST-Base динамика обучения приведена на рисунках 3.3 и 3.4. На рисунке 3.3 видно, что обучающая ошибка быстро уменьшается уже в первые эпохи, тогда как валидационная ошибка после начального участка становится нестабильной. Это типичное поведение для полной донастройки крупной предварительно обученной модели на небольшом и шумном наборе данных.




Рис. 3.3: Динамика функции потерь AST-Base по эпохам

На рисунке 3.4 показаны validation macro F1 и validation balanced accuracy. Значения достигают лучших уровней в первой половине обучения, после чего заметно колеблются. Поэтому выбор лучшего checkpoint по validation macro F1 является более надежным, чем использование последней эпохи.




Рис. 3.4: Динамика валидационных метрик AST-Base по эпохам

3.5 Динамика обучения нейросетевых моделей

Для ResNet18 и CRNN полезно посмотреть не только итоговые тестовые метрики, но и динамику обучения по эпохам. Эти модели значительно меньше AST-Base, поэтому их поведение на валидации лучше отражает ограничения локальных сверточных и гибридных архитектур. Сводка лучших валидационных checkpoint приведена в таблице 3.5.

Таблица 3.5: Лучшие checkpoint по валидационной macro F1

Модель	Эпоха	Train loss	Val loss	Val macro F1	Val weighted F1	Val balance
ResNet18	28	0.0188	3.8828	0.4527	0.2732	0
CRNN GRU	25	0.1231	2.1394	0.4786	0.3816	0
AST-Base	6	0.1572	1.6919	0.6041	0.4819	0

Из таблицы 3.5 видно, что лучшие значения валидационной macro F1 достигаются сильно раньше финальной эпохи. Это особенно заметно для AST-Base: лучший checkpoint получается уже на шестой эпохе, а далее модель начинает терять обобщающую способность. Для ResNet18 и CRNN ранние остановки тоже выглядят предпочтительнее, но абсолютный уровень качества у них ниже, чем у трансформерной модели.

На рисунке 3.5 показано сравнение динамики validation macro F1 для трех нейросетевых моделей. У ResNet18 кривая становится нестабильной уже после первых заметных улучшений. CRNN ведет себя немного ровнее, но не выходит на уровень AST-Base. Трансформерная модель не только достигает более высокого пика, но и дольше сохраняет хорошее качество на валидации.




Рис. 3.5: Сравнение динамики validation macro F1 для нейросетевых моделей

3.5.1 ResNet18

На рисунке 3.6 показана динамика обучения ResNet18. Модель быстро снижает обучающую ошибку, но валидационная ошибка остается высокой и не демонстрирует устойчивого падения. Это означает, что сверточная сеть хорошо подгоняет признаки к обучающей выборке, но не формирует достаточно обобщаемого представления для всех классов одновременно.




Рис. 3.6: Динамика обучения ResNet18

У ResNet18 лучшая валидационная macro F1 достигается на 28-й эпохе, но даже в этот момент значение balanced accuracy остается ниже 0.29. Это указывает на перекося модели в сторону некоторых классов. По сути, сверточная сеть научилась выделять локальные шаблоны, но не смогла надежно связать их с глобальной структурой дыхательного цикла.

3.5.2 CRNN GRU

CRNN использует сверточную часть для извлечения локальных признаков и GRU для моделирования временной последовательности. В сравнении с ResNet18 такая схема дает более высокий пик валидационной macro F1 и заметно более высокий balanced accuracy. Однако улучшение не является достаточно большим, чтобы приблизиться к AST-Base.




Рис. 3.7: Динамика обучения CRNN GRU

CRNN демонстрирует более плавную динамику, чем ResNet18, и достигает лучшего качества на 25-й эпохе. Это объясняется тем, что GRU помогает учитывать последовательность дыхательного цикла, а не только локальную форму спектрограммы. Тем не менее рекуррентный блок не компенсирует ограниченность сверточного представления при работе с редкими и смешанными классами.

В совокупности рисунки 3.5–3.7 показывают, что именно трансформерная архитектура лучше удерживает качество на валидации. Она получает преимущество не только за счет размера модели, но и за счет механизма self-attention, который не требует жесткой локальной последовательности для объединения признаков.

3.6 Результаты

Итоговые агрегированные метрики приведены в таблице 3.6. Основная сбалансированная AST-Base получает лучшие значения accuracy, macro F1 и weighted F1. Контрольный запуск без балансировки немного выше по balanced accuracy, но заметно уступает по weighted F1 и хуже распознает класс `normal`.

Таблица 3.6: Итоговое сравнение моделей на тестовой выборке

Модель	Accuracy	Macro F1	Weighted F1	Balanced accuracy
MFCC + logistic regression	0.4194	0.2878	0.4325	0.2882
ResNet18 log-mel	0.3649	0.3044	0.3865	0.3396
CRNN GRU log-mel	0.3901	0.2998	0.4080	0.3062
AST-Base без балансировки	0.5000	0.4657	0.5181	0.5029
AST-Base с балансировкой	0.5776	0.4867	0.5817	0.4928

Графическое сравнение агрегированных метрик приведено на рисунке 3.8. Визуально видно, что AST-Base не только повышает ассурасу, но и заметно улучшает макро F1 и balanced accuracy, то есть качество по классам в среднем.




Рис. 3.8: Сравнение агрегированных метрик на тестовой выборке

Полнота по каждому классу приведена в таблице 3.7. Сбалансированная AST-Base улучшает полноту классов `normal`, `crackle` и `wheeze` относительно базовых моделей. Контрольный запуск без балансировки сильнее смещается к `crackle` и `both`, но теряет качество на большинстве.

Таблица 3.7: Полнота по классам на тестовой выборке

Модель	normal	crackle	wheeze	both
MFCC + logistic regression	0.5796	0.2888	0.2027	0.0816
ResNet18 log-mel	0.3596	0.4813	0.4054	0.1122
CRNN GRU log-mel	0.4776	0.3850	0.2500	0.1122
AST-Base без балансировки	0.4597	0.7754	0.3581	0.4184
AST-Base с балансировкой	0.6619	0.5241	0.5608	0.2245

Полнота по классам дополнительно показана на рисунке 3.9. Для normal, crackle и wheeze основная AST-Base дает заметный прирост, а для both улучшение остается ограниченным.




Рис. 3.9: Сравнение полноты по классам на тестовой выборке

Таблица 3.8: Точность, полнота и F1-score по классам для AST-Base

Класс	Precision	Recall	F1-score	Support
normal	0.7415	0.6619	0.6994	559
crackle	0.3577	0.5241	0.4252	187
wheeze	0.4826	0.5608	0.5188	148
both	0.4681	0.2245	0.3034	98

Дополнительное графическое представление метрик AST-Base по классам приведено на рисунке 3.10. Оно показывает, что модель хорошо

держит баланс между precision и recall для классов normal и wheeze, но для both уходит в более осторожный режим предсказания: precision относительно высокий, а recall низкий.




Рис. 3.10: Точность, полнота и F1-score AST-Base по классам

Таблица 3.9: Сравнение F1-score по классам для всех моделей

Класс	MFCC	ResNet18	CRNN GRU	AST-Base
normal	0.6119	0.4757	0.5416	0.6994
crackle	0.2776	0.3442	0.2677	0.4252
wheeze	0.1881	0.2837	0.2741	0.5188
both	0.0737	0.1140	0.1158	0.3034

Графическое сравнение F1-score по классам показано на рисунке 3.11. Таблица 3.9 и рисунок 3.11 вместе показывают, что AST-Base выигрывает не только на большинстве класса normal, но и на самых сложных классах wheeze и both. Для crackle прирост тоже есть, но он менее драматичен, что согласуется с тем, что этот класс проще для сверточных моделей, чем тональные и смешанные события.




Рис. 3.11: Сравнение F1-score по классам

Таблица 3.10: Разрыв между лучшей валидацией и тестом по макро F1

Модель	Best val macro F1	Test macro F1	Разница
ResNet18	0.4527	0.3044	0.1483
CRNN GRU	0.4786	0.2998	0.1788
AST-Base	0.6041	0.4867	0.1174

Таблица 3.10 показывает, что у AST-Base не только выше абсолютное качество, но и меньше разрыв между валидацией и тестом. Это означает, что модель лучше переносит настройки, найденные на валидации, на независимую тестовую выборку. У CRNN этот разрыв наиболее заметен, поэтому более высокий валидационный пик не превращается в сопоставимое тестовое качество.

Результаты показывают, что ручные признаки дают приемлемую долю правильных ответов только за счет лучшего распознавания большинства. У модели MFCC + logistic regression accuracy равна 0.4194, но макро F1 составляет только 0.2878. Такой разрыв означает, что модель чаще выбирает частые или более простые классы и слабо распознает редкие варианты дыхательных событий.

ResNet18 снижает recall класса `normal`, но лучше распознает `crackle` и `wheeze`, что отражается в росте `balanced accuracy` до 0.3396. Это показывает, что локальные сверточные признаки на спектрограмме

действительно полезны для событий, которые проявляются как частотно-временные структуры. Однако сверточная модель не дает устойчивого качества по всем классам и остается слабой на `both`.

CRNN оказывается компактнее ResNet18, но не дает значимого улучшения по `macro F1`. Это указывает, что добавление GRU само по себе не решает задачу: временная структура дыхательного цикла полезна, но качество зависит от того, насколько сильное представление формирует сверточная часть перед рекуррентным слоем. В данном эксперименте такой связки недостаточно для заметного прироста.

Сбалансированная AST-Base показывает наиболее высокие значения ключевых агрегированных метрик и становится итоговой выбранной архитектурой. Улучшение `macro F1` до 0.4867 означает, что модель лучше учитывает не только большинство, но и меньшие классы. При этом `weighted F1` 0.5817 показывает, что улучшение сохраняется и при учете фактического распределения тестовой выборки.

Отдельно важно, что режим балансировки меняет распределение ошибок. Для `wheeze` полнота основной AST-Base возрастает до 0.5608, что существенно выше всех базовых моделей. Для `crackle` достигается 0.5241. Класс `both` остается сложным: сбалансированная модель дает `recall` 0.2245, а контрольный запуск без балансировки поднимает его до 0.4184 ценой падения `recall normal` до 0.4597. Это подтверждает, что `self-attention` и предварительное обучение дают информативное представление, но выбор метода работы с дисбалансом задает разные компромиссы между классами.

Таблица 3.8 дополняет этот вывод важной деталью: для `both` `precision` равен 0.4681, то есть модель сравнительно редко ошибочно назначает этот класс, но еще чаще пропускает реальные примеры. Иначе говоря, итоговая проблема связана не столько с ложноположительными ответами, сколько с низкой чувствительностью к редкому смешанному событию. Это полезно для выбора следующих экспериментов, поскольку простое смещение порога или изменение порогового правила уже не решает задачу полностью.

3.7 Анализ ошибок

Кривые обучения AST-Base показывают, что модель быстро подстраивается под обучающую выборку: train loss снижается почти до нуля, тогда как validation loss остается высоким и нестабильным. Это не означает, что модель полностью бесполезна на новых данных, поскольку validation macro F1 и balanced accuracy некоторое время удерживаются на приемлемом уровне. Однако такая динамика указывает на переобучение части параметров под шумы, пациентов и особенности устройств записи. Поэтому в эксперименте принципиально важно выбирать лучший checkpoint по validation macro F1, а не брать последнюю эпоху.

Разница между weighted F1 и macro F1 также важна для интерпретации. Weighted F1 у AST-Base равен 0.5817, а macro F1 равен 0.4867. Более высокое значение weighted F1 связано с тем, что крупные классы вносят больший вклад в среднее. Macro F1 ниже, потому что каждый класс учитывается одинаково, включая редкий и сложный both. Следовательно, итоговое качество нельзя описывать только одной агрегированной метрикой: необходимо одновременно смотреть на macro F1, balanced accuracy и per-class recall.

Основная трудность связана с классом both. Этот класс сочетает признаки crackle и wheeze, но в обучающей выборке представлен только 340 сегментами. Из-за этого модель может относить такие фрагменты к одному из одиночных классов, особенно если один тип события выражен сильнее другого. Даже AST-Base повышает полноту класса both только до 0.2245, что указывает на необходимость дальнейшей работы с дисбалансом и аугментациями.

Классы crackle и wheeze также могут пересекаться по частотно-временным признакам с шумами записи. Короткие хрипы могут быть похожи на шумовые всплески, а свистящие компоненты могут частично сливаться с фоновыми тональными шумами. Разные устройства записи усиливают эту проблему, поскольку изменяют спектральный профиль сигнала.

Еще одним фактором является фиксированная длительность входа 8 секунд. Большая часть дыхательных циклов короче этой длительности, поэтому применяется циклическое дополнение. Оно сохраняет сигнал без заполнения тишиной, но может многократно повторять короткое событие

и тем самым менять относительную структуру фрагмента. Для более точного анализа полезно сравнить циклическое дополнение с нулевым заполнением и случайным `stop/pad`.

С практической точки зрения полученный результат следует считать сильной исследовательской базой, но не финальной устойчивой системой. AST-Base уверенно превосходит базовые модели, однако качество на редких смешанных событиях остается ограниченным. Это задает следующий экспериментальный приоритет: проверка `focal loss`, `SpecAugment`, `mixup`, более мягкого `fine-tuning` с частичным замораживанием `backbone` и подбор длительности входного сегмента.

Еще один полезный вывод состоит в том, что качество разных моделей не следует оценивать только по одному числу. У `ResNet18` и `CRNN` есть локальные пики валидации, но они не превращаются в устойчивое качество на тестовой выборке. AST-Base, напротив, показывает более высокий пик и более высокий итоговый результат. Значит, в задаче распознавания дыхательных звуков важны одновременно предварительное обучение, достаточно выразительное представление спектрограммы и механизм, который способен связывать удаленные участки сигнала.

Наконец, разрыв между `validation macro F1` и `test macro F1` показывает, что задача остается чувствительной к особенностям конкретного разбиения. Это не ошибка реализации, а свойство малого и неоднородного датасета. Поэтому дальнейшее улучшение должно идти не только через выбор более мощной модели, но и через более аккуратную работу с разметкой, аугментациями и режимами оценки.

3.8 Работа с несбалансированной выборкой

Исходное распределение обучающей выборки является несбалансированным: класс `normal` содержит 2597 сегментов, а класс `both` – только 340 сегментов. Поэтому в работе отдельно проверены два режима AST-Base. Первый режим использует исходную выборку без специальных мер. Второй режим применяет `weighted sampler` и `weighted cross entropy`, то есть чаще подает редкие классы в пакет и одновременно увеличивает их вклад в функцию потерь.

Сравнение этих режимов приведено в таблице 3.11. Контрольный за-

пуск без балансировки был остановлен после 29-й эпохи, поскольку лучший validation macro F1 был достигнут на 22-й эпохе и далее не улучшался. Для теста использован сохраненный лучший checkpoint.

Таблица 3.11: Сравнение AST-Base без балансировки и с балансировкой

Режим	Macro F1	Weighted F1	Balanced acc	Recall both
Без балансировки	0.4657	0.5181	0.5029	0.4184
Weighted sampler + loss	0.4867	0.5817	0.4928	0.2245

Таблица 3.11 показывает, что балансировка не дает однозначного выигрыша по каждой отдельной метрике. Без балансировки модель сильнее реагирует на классы crackle и both, поэтому recall both выше. Однако такой выигрыш достигается ценой падения recall normal до 0.4597 и снижения weighted F1 до 0.5181. Сбалансированный режим повышает macro F1 и weighted F1, поэтому выбран как основной: он дает более ровное качество на фактическом тестовом распределении и меньше разрушает качество большинства.

Таблица 3.12: Подготовленные методы работы с дисбалансом

Метод	Назначение
Взвешенная функция потерь	увеличивает штраф за ошибки на редких классах
Weighted sampler	выравнивает частоту появления классов в обучающих пакетах
Focal loss	усиливает вклад трудных примеров и уменьшает вклад уверенно распознанных объектов
Аугментация меньших классов	увеличивает разнообразие crackle, wheeze и both без изменения validation и test split

Аугментация реализована на двух уровнях. На уровне сигнала используются случайное изменение амплитуды, циклический временной

сдвиг и добавление слабого гауссова шума. На уровне log-mel спектрограммы используется маскирование полос по частоте и времени. Эти преобразования применяются только к обучающим примерам меньших классов `crackle`, `wheeze` и `both`. Такой выбор сохраняет неизменными валидационную и тестовую выборки, поэтому сравнение метрик остается корректным.

3.9 Выводы по практической части

Практическая часть подтвердила, что трансформерная архитектура AST-Base является лучшим вариантом среди реализованных моделей. По сравнению с MFCC + logistic regression значение макро F1 выросло с 0.2878 до 0.4867, а balanced accuracy – с 0.2882 до 0.4928. По сравнению с лучшим нетрансформерным baseline ResNet18 значение макро F1 выросло с 0.3044 до 0.4867, а balanced accuracy – с 0.3396 до 0.4928.

Сравнение AST-Base без балансировки и с балансировкой показало, что несбалансированная выборка меняет компромисс между классами, а не просто ухудшает все метрики одновременно. Контрольный запуск без балансировки получил `recall both` 0.4184, но снизил `weighted F1` до 0.5181 и `recall normal` до 0.4597. Сбалансированный режим получил более высокий макро F1 0.4867 и `weighted F1` 0.5817, поэтому он оставлен основным.

Полученный конвейер воспроизводимо строит индекс данных, формирует пациент-независимые разбиения, извлекает признаки, обучает несколько семейств моделей и сохраняет артефакты экспериментов. Для дальнейшей работы с редкими классами добавлены конфигурации `focal loss` и аугментации меньших классов на уровне сигнала и log-mel спектрограммы.

Заключение

В работе исследована задача автоматической классификации дыхательных аудиозаписей по разметке дыхательных циклов. Рассмотрены особенности исходных данных, включая шум, разные устройства записи, различную длительность фрагментов и выраженный дисбаланс классов. Сформулирована математическая постановка задачи многоклассовой классификации аудиосегментов и описаны метрики, необходимые для корректной оценки качества на несбалансированных данных.

Проведен обзор основных семейств методов: классических моделей на ручных признаках, сверточных сетей на спектрограммах, сверточно-рекуррентных моделей и трансформерных аудиоархитектур. В качестве основной архитектуры выбрана AST-Base, поскольку она работает с логарифмическими мел-спектрограммами, использует предварительно обученное аудиопредставление и содержит 86м параметров, что меньше заданного ограничения 100 млн параметров.

В практической части реализован конвейер от сырого аудио до метрик качества. Подготовлен индекс из 6898 размеченных сегментов, сформированы пациент-независимые train, validation и test split, реализованы модели MFCC + logistic regression, ResNet18, CRNN GRU и AST-Base. Качество оценено по accuracy, macro F1, weighted F1, balanced accuracy и полноте по каждому классу.

Лучший результат среди основных моделей показала сбалансированная AST-Base: accuracy 0.5776, macro F1 0.4867, weighted F1 0.5817 и balanced accuracy 0.4928. Модель улучшила ключевые агрегированные метрики относительно ручных признаков, ResNet18 и CRNN. Отдельное сравнение с AST-Base без балансировки показало, что дисбаланс меняет распределение ошибок: контрольный режим повышает recall both до 0.4184, но снижает weighted F1 и качество большинства. Поэтому weighted sampler и взвешенная функция потерь выбраны как основной режим обучения.

Дальнейшее развитие работы целесообразно связать с запуском focal-loss ablation, применением добавленных аугментаций сигнала и спектрограмм, более строгой настройкой балансировки классов, срав-

нением нескольких вариантов фиксированной длительности входа и проверкой переносимости результата на других наборах дыхательных аудиозаписей.

Литература

- [1] Rocha B. M., Filos D., Mendes L., et al. An open access database for the evaluation of respiratory sound classification algorithms. *Physiological Measurement*. 2019. Vol. 40, No. 3. doi:10.1088/1361-6579/ab03ea.
- [2] Gong Y., Chung Y.-A., Glass J. AST: Audio Spectrogram Transformer. *Proceedings of Interspeech*. 2021. arXiv:2104.01778.
- [3] He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition. *Proceedings of CVPR*. 2016. arXiv:1512.03385.
- [4] Cakir E., Parascandolo G., Heittola T., Huttunen H., Virtanen T. Convolutional Recurrent Neural Networks for Polyphonic Sound Event Detection. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. 2017. arXiv:1702.06286.
- [5] Davis S., Mermelstein P. Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. 1980. doi:10.1109/TASSP.1980.1163420.
- [6] Park D. S., Chan W., Zhang Y., et al. SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition. *Proceedings of Interspeech*. 2019. arXiv:1904.08779.
- [7] Lin T.-Y., Goyal P., Girshick R., He K., Dollar P. Focal Loss for Dense Object Detection. *Proceedings of ICCV*. 2017. arXiv:1708.02002.
- [8] Gemmeke J. F., Ellis D. P. W., Freedman D., et al. Audio Set: An ontology and human-labeled dataset for audio events. *Proceedings of ICASSP*. 2017. research.google/pubs/audio-set.
- [9] Wang H., Liu J., Hu Y., et al. SPRSound: Open-Source Shenzhen Pediatric Respiratory Sound Database. *IEEE Transactions on Biomedical Engineering*. 2022. doi:10.1109/TBME.2022.3205189.

- [10] Sharma N., Krishnan P., Kumar R., et al. Coswara – A Database of Breathing, Cough, and Voice Sounds for COVID-19 Diagnosis. *Proceedings of Interspeech*. 2020. arXiv:2005.10548.

Глава А. Конфигурации и команды запуска

А.1 Подготовка индекса данных

Листинг А.1 показывает команду подготовки индексной таблицы сегментов. Перед запуском серверной команды проект синхронизируется через Mutagen.

Листинг А.1: Команда подготовки индексной таблицы

```
1 mutagen project flush
2 ssh JH 'cd /home/margasanov/temki/diplom && conda run -p /opt/
   gen-content/margasanov/envs/pizding-kartochek python -m src
   .data.index --config configs/data/default.yaml'
```

А.2 Команды обучения

Листинг А.2 содержит команды запуска завершенных экспериментов. Все команды выполняются на сервере JH в рабочей conda-среде.

Листинг А.2: Команды обучения моделей

```
1 mutagen project flush
2 ssh JH 'cd /home/margasanov/temki/diplom && conda run -p /opt/
   gen-content/margasanov/envs/pizding-kartochek python -m src
   .train --config configs/experiments/ml_mfcc_logreg.yaml'
3 ssh JH 'cd /home/margasanov/temki/diplom && conda run -p /opt/
   gen-content/margasanov/envs/pizding-kartochek python -m src
   .train --config configs/experiments/resnet18.yaml'
4 ssh JH 'cd /home/margasanov/temki/diplom && conda run -p /opt/
   gen-content/margasanov/envs/pizding-kartochek python -m src
   .train --config configs/experiments/crnn_gru.yaml'
5 ssh JH 'cd /home/margasanov/temki/diplom && conda run -p /opt/
   gen-content/margasanov/envs/pizding-kartochek python -m src
   .train --config configs/experiments/ast_base.yaml'
```

А.3 Гиперпараметры моделей

Таблица А.1 сводит основные гиперпараметры завершенных экспериментов.

Таблица A.1: Основные гиперпараметры экспериментов

Модель	Batch size	Epochs	Learning rate	Loss
MFCC + logistic regression	—	—	—	balanced class weight
ResNet18	16	30	0.0003	weighted CE
CRNN GRU	16	30	0.0003	weighted CE
AST-Base	8	50	0.00005	weighted CE

A.4 Модульная структура реализации

Таблица A.2 показывает назначение основных модулей проекта.

Таблица A.2: Модульная структура реализации

Модуль	Назначение
src/data/	Чтение аудио, разбор аннотаций, построение индекса
src/features/	MFCC/statistics и log-mel признаки
src/models/	Logistic regression, ResNet, CRNN, AST
src/train.py	Обучение моделей и сохранение артефактов
src/evaluate.py	Повторная оценка checkpoint
src/report.py	Агрегация метрик запусков
configs/	Конфигурации данных и экспериментов
EXPS/	Карточки проведенных экспериментов